

TRABAJO FIN DE GRADO

GRADO EN INTELIGENCIA Y ANALÍTICA DE NEGOCIOS

INTELIGENCIA ARTIFICIAL Y
OPTIMIZACIÓN DE CARTERAS: UNA
NUEVA ERA EN LAS FINANZAS
CUANTITATIVAS

ALUMNO/A:

Mario Martínez Escrivá

TUTOR/A:

Pedro David Ruíz Femenía

DEPARTAMENTO DEL TUTOR:

Matemáticas, Economía y Empresa

CURSO ACADÉMICO:

2024-2025

FECHA DE DEPÓSITO:

16/06/2025



RESUMEN

Este trabajo analiza el impacto de la inteligencia artificial en la optimización de carteras. Para ello se revisan sus principales tendencias, usos y repercusiones en el contexto financiero contemporáneo. Además, se presenta un caso práctico en el que se compara el modelo clásico de Markowitz con dos planteamientos basados en aprendizaje profundo: un agente de Deep Reinforcement Learning entrenado mediante PPO y un modelo predictivo basado en redes LSTM. A partir de datos reales de mercado, se demuestra que los modelos de IA pueden superar significativamente al enfoque tradicional en términos de rentabilidad ajustada al riesgo, gracias a su capacidad de aprendizaje y adaptación a entornos dinámicos.

Palabras clave: *Inteligencia artificial, aprendizaje profundo, optimización de carteras, Deep Reinforcement Learning, LSTM, modelo de Markowitz*

ABSTRACT

This study analyzes the impact of artificial intelligence on portfolio optimization. To this end, it reviews its main trends, applications, and implications in the contemporary financial context. In addition, a practical case is presented in which the classical Markowitz model is compared with two deep learning-based approaches: a Deep Reinforcement Learning agent trained using PPO and a predictive model based on LSTM networks. Using real market data, it is demonstrated that AI models can significantly outperform the traditional approach in terms of risk-adjusted returns, thanks to their ability to learn and adapt to dynamic environments.

Keywords: *Artificial intelligence, deep learning, portfolio optimization, Deep Reinforcement Learning, LSTM, Markowitz model*

ÍNDICE GENERAL

1. INTRODUCCIÓN.....	6
1.1. Principios y problemas generales de inversión.....	6
1.2. Tipos de activos en los mercados financieros.....	7
1.3. Formas populares de análisis.....	9
2. METODOLOGÍA	11
3. EL IMPACTO DE LA TECNOLOGÍA Y LA INTELIGENCIA ARTIFICIAL EN LA OPTIMIZACIÓN DE CARTERAS.....	13
3.1. Machine Learning y sector financiero.....	13
3.2. Tendencias de la IA y el Machine Learning en la gestión de activos.....	14
3.3. Volumen de activos gestionados con IA/ML.....	15
3.4. Tendencias tecnológicas emergentes	15
3.5. Barreras, desafíos y retos.....	17
4. FUNDAMENTOS TEÓRICOS DE LA OPTIMIZACIÓN DE CARTERAS	19
4.1. Rentabilidad y riesgo	19
4.2. Correlación y diversificación	20
4.3. Teoría de cartera media-varianza de Markowitz.....	22
4.4. Benchmark y retorno residual.....	27
4.5. El equilibrio de mercado	28
5. MÉTODOS BASADOS EN APRENDIZAJE PROFUNDO	31
5.1. Redes neuronales profundas (Deep Neural Networks, DNN)	31
5.2. Redes neuronales recurrentes.....	32
5.3. Redes de Aprendizaje por Refuerzo Profundo (Deep Reinforcement Learning).....	34
5.4. Otros métodos avanzados: Autoencoders y Transformers	35
6. EL MODELO DE MARKOWITZ EN LA PRÁCTICA.....	37
6.1. Universo de inversión.....	37
6.2. Implementación del modelo de optimización media-varianza	38
6.2.1. Datos y pasos previos.....	38
6.2.2. Generación de la frontera eficiente.....	39
6.2.3. Configuración y pesos de los activos en la cartera óptima.....	41
6.3. Evaluación de la cartera tangente	43

7. IMPLEMENTACIÓN DE MODELOS DE APRENDIZAJE PROFUNDO Y COMPARATIVA CON OPTIMIZACIÓN DE MARKOWITZ	45
7.1. Optimización con Deep Reinforcement Learning (DRL)	45
7.1.1. Datos y pasos previos.....	45
7.1.2. Definición del entorno personalizado de inversión.....	46
7.1.3. Implementación del agente PPO	48
7.1.4. Evaluación del agente PPO y construcción de la cartera	50
7.1.5. Evaluación de la cartera construida con DRL	52
7.2. Optimización con predicciones LSTM	52
7.2.1. Datos y pasos previos.....	53
7.2.2. Configuración del método Bi-LSTM.....	54
7.2.3. Validación del método Bi-LSTM	56
7.2.4. Predicción fuera de muestra (2023-2024).....	60
7.2.5. Construcción de la cartera a partir de las predicciones LSTM	64
7.3. Comparativa final entre las distintas optimizaciones	67
8. CONCLUSIONES Y LIMITACIONES	70
ANEXOS	72
ANEXO I: CARTERA DE MARKOWITZ CON R	72
ANEXO II: CARTERA DRL CON PYTHON	75
ANEXO III: CARTERA LSTM CON PYTHON	80
BIBLIOGRAFÍA.....	87

TABLA DE FIGURAS

FIGURA 1. AGENTES DISRUPTIVOS Y SU CONTRIBUCIÓN ESPERADA AL CAMBIO INDUSTRIAL	14
FIGURA 2. RENTABILIDAD Y RIESGO PARA CINCO ACTIVOS	23
FIGURA 3. DOS ACTIVOS Y SUS COMBINACIONES.....	24
FIGURA 4. POSIBILIDADES DE UN PORTAFOLIO Y LA FRONTERA EFICIENTE.....	25
FIGURA 5. LA FRONTERA EFICIENTE Y CURVAS DE INDIFERENCIA.....	26
FIGURA 6. RIESGO RESIDUAL Y EFICIENCIA DEL RETORNO DEL PORTAFOLIO	27
FIGURA 7. FRONTERA EFICIENTE DE LA OPTIMIZACIÓN MEDIA-VARIANZA DE MARKOWITZ	40
FIGURA 8. PESOS DE LOS ACTIVOS EN EL PORTAFOLIO DE MERCADO.....	41
FIGURA 9. PESOS DE LOS ACTIVOS EN LA CARTERA DRL	51
FIGURA 10. COMPARATIVA MARKOWITZ VS DRL (23-24)	52
FIGURA 11. PREDICCIONES DE LSTM EN EL CONJUNTO DE VALIDACIÓN	59
FIGURA 12. PRONÓSTICOS DE LSTM PARA LOS AÑOS 2023-2024	63
FIGURA 13. PESOS DE LOS ACTIVOS EN LA CARTERA LSTM.....	66
FIGURA 14. COMPARATIVA ENTRE CARTERAS (MARKOWITZ VS LSTM VS DRL)	67

1. INTRODUCCIÓN

1.1. Principios y problemas generales de inversión

La inversión consiste en destinar recursos en el presente con la expectativa de obtener beneficios en el futuro. En el ámbito financiero, implica emplear dinero hoy con la esperanza de recibir una cantidad mayor más adelante. Este concepto está estrechamente ligado a uno de los principios fundamentales de las finanzas: el valor temporal del dinero. Un euro hoy tiene más valor que un euro en el futuro debido a las oportunidades de inversión disponibles. En lugar de mantener el dinero inactivo, se puede invertir en activos financieros, empresas o prestarlo a cambio de intereses. Este principio es la base de la valoración de inversiones y del cálculo de tasas de descuento en proyectos financieros.

En la mayoría de los casos, la rentabilidad de una inversión no está asegurada y está sujeta a incertidumbre. Por ello, el análisis de inversiones es un proceso esencial que implica comparar distintas alternativas para seleccionar la más adecuada en función del riesgo y la rentabilidad esperada.

Lo que distingue a las decisiones de inversión de otros tipos de decisiones económicas es el entorno en el que se desarrollan: los mercados financieros. A diferencia de otros escenarios de decisión, los mercados ofrecen un abanico de opciones de inversión caracterizado por su diversidad y accesibilidad. En este sentido, un principio fundamental en el análisis de inversiones es el principio de comparación, según el cual una inversión debe evaluarse no de forma aislada, sino en relación con las oportunidades disponibles en el mercado.

Otro rasgo esencial de los mercados financieros es su naturaleza dinámica. Los precios de los activos no son fijos, sino que fluctúan constantemente debido a factores como la oferta y la demanda, noticias económicas y decisiones de política monetaria. Por lo tanto, el análisis de inversiones no se centra únicamente en estimar un valor futuro para un activo, sino en modelar su evolución bajo condiciones de incertidumbre.

Asimismo, otro principio fundamental en el proceso de inversión es la aversión al riesgo. Los inversores, en general, prefieren minimizar la incertidumbre y proteger su capital, por lo que exigen una compensación adecuada al asumir mayores riesgos. Así, cuando dos inversiones ofrecen la misma rentabilidad esperada, los inversores racionales eligen la opción con menor riesgo. La construcción óptima de una cartera busca el mejor equilibrio entre riesgo y rentabilidad. Sin embargo, ni los rendimientos ni los riesgos de los activos financieros son leyes inmutables. A diferencia de las ciencias exactas, en

finanzas no es posible realizar experimentos controlados para determinar un "valor verdadero" de un activo. Cada inversor debe evaluar sus propias preferencias y definir el equilibrio que desea entre riesgo y rentabilidad. No existe una única respuesta correcta, ya que las decisiones dependen en gran medida del juicio personal y los objetivos individuales.

1.2. Tipos de activos en los mercados financieros

Los mercados financieros ofrecen una amplia gama de activos que los inversores pueden utilizar para diversificar sus carteras y optimizar la relación entre rentabilidad y riesgo. A continuación, se describen los principales tipos de activos y sus características fundamentales.

Acciones

Las acciones son participaciones en la propiedad de una empresa, lo que otorga a los inversores derechos sobre sus beneficios y, en ciertos casos, influencia en las decisiones corporativas. Su atractivo radica en la posibilidad de generar rendimientos tanto a través del incremento en su precio como del pago de dividendos, los cuales pueden distribuirse de manera trimestral, semestral o anual. Sin embargo, su valor fluctúa en función de la volatilidad del mercado y de factores internos de la compañía, siendo así activos con un nivel de riesgo considerable.

Materias Primas (Commodities)

Las materias primas incluyen productos físicos como metales preciosos (oro, plata), energéticos (petróleo, gas) y productos agrícolas (trigo, maíz, café). Son activos cuyo precio está determinado por la oferta y la demanda global, con una gran influencia de factores macroeconómicos y geopolíticos. El oro, en particular, es considerado un activo refugio en periodos de inflación e incertidumbre socioeconómica, debido a su estabilidad y aceptación universal como reserva de valor. La mayoría de las transacciones con commodities se realizan en el mercado de futuros. De esta forma, los inversores pueden especular sobre sus precios sin necesidad de poseer físicamente los bienes.

Renta Fija

Los bonos son instrumentos de deuda emitidos por gobiernos, corporaciones y otras entidades con el fin de captar financiamiento. Estos activos ofrecen pagos periódicos de intereses y la devolución del capital invertido al vencimiento del bono.

Existen diferentes tipos de bonos según la estructura de pagos y el emisor, entre ellos:

- Bonos de tasa fija: Ofrecen un pago de interés constante durante su vigencia.
- Bonos de tasa variable: Su cupón varía en función de tasas de referencia como el Euríbor o la LIBOR.
- Bonos ligados a la inflación: Protegen el poder adquisitivo del inversor al ajustar sus pagos según un índice de precios, como el RPI en el Reino Unido o el TIPS en EE.UU.

Mercado de Divisas (Forex)

El mercado Forex permite la compraventa de monedas extranjeras. Es el mercado financiero más líquido a nivel global. Algunas divisas tienen tipos de cambio flotantes, mientras que otras están vinculadas a monedas de mayor estabilidad. A través de la negociación en este mercado, los inversores pueden beneficiarse de la variación en los tipos de cambio y realizar operaciones de cobertura para reducir el riesgo cambiario.

Índices Bursátiles

Los índices bursátiles reflejan el rendimiento de un grupo de activos o de un sector específico del mercado. Son utilizados como referencia para evaluar el comportamiento general del mercado y sirven de base para instrumentos financieros como los fondos cotizados (ETF). Ejemplos de índices relevantes incluyen:

- S&P 500 (EE.UU.): Representa las 500 empresas más importantes de la bolsa estadounidense.
- FTSE 100 (Reino Unido): Índice de las 100 principales empresas listadas en la Bolsa de Londres.
- DAX 40 (Alemania): Representa las 40 principales compañías alemanas que cotizan en la Bolsa de Frankfurt.
- Hang Seng Index (Hong Kong): Compuesto por las mayores empresas que cotizan en la Bolsa de Hong Kong, reflejando la economía china y regional.
- Ibex 35 (España): Representa las 35 empresas con mayor liquidez en la Bolsa española.
- EMBI+ (Mercados Emergentes): Mide el rendimiento de bonos emitidos por países en desarrollo.

Derivados Financieros

Los derivados son instrumentos cuyo valor depende del activo subyacente al que están vinculados. Se utilizan tanto para especulación como para cobertura de riesgos:

- **Forwards:** Contratos personalizados entre dos partes para la compra o venta de un activo en una fecha futura y a un precio acordado, sin que se intercambie dinero hasta el vencimiento.
- **Futuros:** Similares a los forwards, pero negociados en mercados organizados y con liquidaciones diarias que mitigan el riesgo de incumplimiento.
- **Opciones:** Contratos que otorgan al comprador el derecho, pero no la obligación, de comprar (call) o vender (put) un activo a un precio determinado antes o en una fecha específica.
- **CFDs (Contratos por Diferencia):** Permiten a los inversores especular sobre la variación de precios de un activo sin poseerlo físicamente. Son populares en mercados de renta variable, materias primas y divisas.
- **Swaps:** Contratos en los que dos partes acuerdan intercambiar flujos de efectivo, como el canje de tasas de interés fija por variable para optimizar costes financieros.

Criptoactivos

Los criptoactivos, con Bitcoin a la cabeza, han surgido como una nueva categoría dentro del mundo financiero. Su atractivo principal se basa en su naturaleza descentralizada, el uso de tecnología blockchain y su potencial para generar elevados rendimientos. No obstante, se caracterizan por una volatilidad mucho más pronunciada en comparación con los activos financieros tradicionales.

1.3. Formas populares de análisis

En el mundo financiero, existen tres enfoques principales para el análisis de inversión: el análisis fundamental, el análisis técnico y el análisis cuantitativo.

Análisis Fundamental

El análisis fundamental busca determinar el valor intrínseco de una empresa mediante el estudio detallado de sus estados financieros, la calidad del equipo directivo, la solidez de sus ventajas competitivas, la situación de su industria y otros factores relevantes. Este método es utilizado por inversores que buscan identificar activos con un precio inferior a su valor intrínseco y con potencial de revalorización a largo plazo.

Sin embargo, presenta ciertas limitaciones. En primer lugar, su aplicación requiere acceso a información detallada que no siempre es fácilmente verificable. En segundo lugar, incluso si se logra una valoración precisa de una empresa, los mercados pueden mantener una cotización alejada de su valor fundamental durante un período prolongado y dificultar así la materialización de la inversión en términos de rentabilidad.

Análisis Técnico

El análisis técnico se fundamenta en el examen de los movimientos pasados del precio y del volumen de negociación de un activo, sin considerar factores fundamentales. Su objetivo es identificar patrones y tendencias en los gráficos que puedan anticipar la evolución futura del mercado. Para ello, emplea herramientas como medias móviles, indicadores de momentum y figuras chartistas. No obstante, la investigación académica indica que muchos de sus métodos carecen de un respaldo teórico sólido y su eficacia puede ser limitada (Wilmott, 2007).

Análisis Cuantitativo

El análisis cuantitativo se ha consolidado en las últimas décadas como una de las metodologías más eficaces en el estudio de los mercados financieros. Esta aproximación se apoya en modelos matemáticos y estadísticos para describir el comportamiento de variables como los precios de los activos y los índices de mercado, considerándolos como procesos aleatorios. Gracias a esta metodología, se han desarrollado herramientas fundamentales para la valoración de derivados, la gestión del riesgo y la optimización de carteras. Además, el análisis cuantitativo ha permitido la creación de estrategias de inversión sistemáticas, como el trading algorítmico y los modelos de arbitraje estadístico, que buscan aprovechar ineficiencias del mercado mediante técnicas avanzadas de procesamiento de datos.

En este trabajo, el énfasis estará en el análisis cuantitativo. De este modo, se abordará la toma de decisiones de inversión con fundamento en modelos matemáticos y estadísticos. Se abarcará desde métodos tradicionales hasta técnicas basadas en inteligencia artificial.

2. METODOLOGÍA

Este estudio adopta una metodología mixta, combinando una revisión teórica con un desarrollo práctico detallado. El objetivo es analizar el impacto real de la inteligencia artificial en la optimización de carteras, no solo desde un punto de vista conceptual, sino también demostrando su aplicabilidad a través de modelos implementados con datos reales de mercado.

La estructura del trabajo se articula en torno a cinco grandes fases:

1. Contextualización tecnológica y sectorial: Se analiza el papel emergente de la inteligencia artificial y el aprendizaje automático en el ámbito financiero, con especial atención a sus aplicaciones en la gestión de activos. Esta parte incluye casos de uso relevantes y los desafíos regulatorios, interpretativos y técnicos que acompañan a su adopción.
2. Fundamentos teóricos de la optimización de carteras: Se abordan los conceptos clave que sustentan la teoría financiera clásica, como la relación entre rentabilidad y riesgo, la importancia de la correlación y la diversificación, el modelo media-varianza de Markowitz y las nociones de equilibrio de mercado. Esta base permitirá entender tanto los límites de los métodos tradicionales como la motivación para explorar modelos alternativos basados en IA.
3. Exploración de métodos de aprendizaje profundo: Se exponen las principales arquitecturas de Deep Learning utilizadas en la optimización de carteras, desde redes neuronales profundas (DNN) hasta redes recurrentes (LSTM), modelos de aprendizaje por refuerzo (DRL), Autoencoders y Transformers. Se detallan sus ventajas teóricas y sus aplicaciones más comunes en la selección de activos, predicción de retornos y asignación de pesos.
4. Implementación práctica y comparativa empírica: Se lleva a cabo una implementación computacional con datos reales, comparando tres estrategias: el modelo clásico de Markowitz, un agente de Deep Reinforcement Learning entrenado con PPO y un sistema basado en predicciones de precios generadas con modelos LSTM. Todas las carteras se evalúan en condiciones realistas fuera de muestra durante el periodo 2023-2024, con métricas homogéneas de rentabilidad, riesgo y ratio de Sharpe.
5. Análisis de resultados, conclusiones y limitaciones: Finalmente, se interpretan los resultados obtenidos, se identifican los puntos fuertes y débiles de cada método y se reflexiona sobre las implicaciones prácticas de la aplicación de IA

en carteras reales. Se abordan también las limitaciones del estudio, tanto metodológicas como estructurales.

Con este diseño metodológico se busca aportar una visión completa, crítica y aplicable del uso de inteligencia artificial en la optimización de carteras.

3. EL IMPACTO DE LA TECNOLOGÍA Y LA INTELIGENCIA ARTIFICIAL EN LA OPTIMIZACIÓN DE CARTERAS

3.1. Machine Learning y sector financiero

El Machine Learning (ML), una disciplina clave dentro de la Inteligencia Artificial (IA), busca capacitar a las computadoras para aprender a partir de datos sin necesidad de una programación explícita para cada tarea. Su funcionamiento se basa en la aplicación de algoritmos y técnicas estadísticas que permiten identificar patrones, extraer conocimiento y generar predicciones. Con el tiempo, estos sistemas pueden convertir grandes volúmenes de datos en información valiosa y facilitar la toma de decisiones tanto para las máquinas como para los seres humanos, reduciendo así el margen de error en distintos procesos.

El crecimiento de la IA y el Machine Learning ha sido impulsado por avances tecnológicos recientes, como el aumento exponencial en la generación de datos a través de dispositivos interconectados y la constante interacción en línea, que genera grandes cantidades de información en tiempo real. Además, la reducción en los costes de almacenamiento y el desarrollo de la computación en la nube han mejorado la eficiencia en el procesamiento y acceso a estos datos. Estos factores han favorecido la adopción del Machine Learning en diversas industrias, incluyendo el sector financiero, donde estos modelos han ganado protagonismo por su capacidad para adaptarse a entornos de alta incertidumbre. Su utilidad es particularmente notable en contextos donde las relaciones matemáticas no son fácilmente definibles, en la detección de patrones no lineales y en escenarios donde las variables presentan una estabilidad limitada.

Varios estudios han demostrado su eficacia y su adopción no deja de crecer por parte de entidades financieras como bancos, aseguradoras y gestoras de activos (Jung, Mueller, Pedemonte, Plances, & Thew, 2019).

El impacto del ML en el sector financiero se extiende a múltiples áreas de aplicación. Según revisiones sistemáticas de la literatura, las principales áreas donde esta tecnología está siendo utilizada incluyen: riesgo de crédito y concesión de préstamos, prevención del fraude y detección de anomalías, predicción de variables económicas y financieras, personalización de servicios financieros mediante análisis de comportamiento, valoración de activos y, de una forma prometedora, la gestión y optimización de carteras (Goodell, Kumar, Lim, & Pattnaik, 2021).

3.2. Tendencias de la IA y el Machine Learning en la gestión de activos

Una encuesta realizada en 2022 entre más de 2.000 miembros del CFA Institute predijo que métodos analíticos nuevos como el Machine Learning serían los principales disruptores de los roles laborales en los próximos 5 a 10 años.




Figura 1. Agentes disruptivos y su contribución esperada al cambio industrial

Fuente: (CFA Institute, 2022)

La tendencia ha sido acelerada por la entrada de grandes tecnológicas (BigTech) en el sector financiero, las cuales lideran el desarrollo de herramientas avanzadas para la toma de decisiones basadas en datos (Banco de España, 2022).

Gestoras de activos tradicionales como BlackRock, Vanguard o Allianz Global Investors han incorporado algoritmos de ML en distintas etapas del proceso inversor. Por ejemplo, BlackRock ha potenciado su plataforma Aladdin con análisis predictivos basados en ML para evaluar riesgos de cartera y stress tests avanzados (Wikipedia, 2024). El propio CEO de BlackRock ha señalado que la “vieja forma” de seleccionar activos manualmente está dando paso a estrategias basadas en Big Data e IA (Swedroe, 2023).

Robo-advisors como Betterment o Wealthfront emplean algoritmos para optimizar asignaciones según el perfil de riesgo del cliente. De esta forma, ajustan dinámicamente las carteras. En 2023, los activos gestionados por plataformas digitales (robo-advisors

y neo-brokers) alcanzaron \$2,26 billones de USD, un salto exponencial desde apenas \$3.800 millones en 2017. Esta masificación es un reflejo de cómo la gestión automatizada se ha vuelto asequible y popular: más de 500 millones de usuarios utilizan ya estos servicios, frente a solo 15 millones en 2017 (Funds Society, 2024).

Casos de uso destacados evidencian resultados cuantitativos del empleo de IA/ML en la gestión de carteras. Un ejemplo reciente es Minotaur Capital, un hedge fund lanzado en 2023 que opera sin analistas humanos, confiando plenamente en modelos de IA para seleccionar activos y gestionar el portafolio. En sus primeros seis meses, su fondo global obtuvo un +18,7% de rentabilidad, superando claramente al S&P 500 con +11,9% en el mismo periodo. Además, Minotaur reporta que su metodología algorítmica redujo a la mitad los costes operativos en comparación con un equipo humano tradicional (Šibalić, 2025).

3.3. Volumen de activos gestionados con IA/ML

Cuantificar exactamente cuántos activos están siendo gestionados mediante IA/ML es complejo, dado que muchas instituciones utilizan estas herramientas de forma parcial, por ejemplo, como apoyo al gestor y no de manera totalmente autónoma. No obstante, algunas métricas ilustran la escala creciente. A nivel global, más de la mitad de las gestoras (54%) ya utilizan IA en sus estrategias de inversión o investigación, y otro 37% planea hacerlo en el corto plazo (Mercer, 2024). Por otra parte, 9 de cada 10 hedge funds a nivel mundial reportan usar IA para impulsar sus retornos (Shirgaonkar, 2023).

Sin embargo, son todavía pocos los fondos de inversión que se comercializan abiertamente como “gestionados por IA”. Conviene notar que en muchos casos la IA actúa como copiloto del gestor humano, aportando señales o recomendaciones, más que reemplazar completamente la toma de decisiones. Por ende, el volumen exacto “gestionado por IA” depende de la definición: desde el enfoque más estricto con fondos 100% cuantitativos basados en ML, que aún representan un nicho, hasta un criterio más amplio que incluya activos donde la IA contribuye al proceso de inversión, en cuyo caso la penetración ya es considerable en las grandes gestoras globales.

3.4. Tendencias tecnológicas emergentes

Mirando al futuro próximo, se vislumbran algunas tendencias emergentes en el uso de IA/ML para la optimización de carteras y mercados financieros que podrían consolidarse:

- Modelos fundacionales en finanzas: La revolución de los modelos gigantes pre-entrenados (Large Language Models y otras arquitecturas de IA fundacional) también ha alcanzado al sector financiero. Ya en 2023 se introdujo

BloombergGPT, un LLM de 50.000 millones de parámetros entrenado con un enorme corpus de datos financieros para realizar tareas de Natural Language Processing (NLP) con alto nivel de comprensión contextual (Wu, y otros, 2023).

De cara a los próximos años, es previsible que los grandes actores desarrollen modelos fundacionales propios o adaptados (fine-tuned) para múltiples aplicaciones, desde asesoramiento automatizado hasta detección de fraudes (Finio & Downie, 2024). Un caso de uso concreto es la asesoría virtual de inversiones: modelos al estilo ChatGPT capaces de dialogar con clientes, explicar estrategias de cartera y responder preguntas financieras complejas con lenguaje natural, lo que puede revolucionar el robo-advisory. Las proyecciones de Deloitte apuntan a que las herramientas de IA generativa podrían alcanzar el 78% de cuota mental como fuente de consejo para inversores minoristas en 2028, convirtiéndose en la principal vía de asesoramiento (Simmonds, Waz, & Dannemiller, 2024).

En el ámbito profesional, ejemplos reales como Morgan Stanley Assistant muestran que más del 98% de los equipos de asesores ya utilizan internamente un chatbot basado en GPT-4 para resumir informes, filtrar noticias y responder consultas, actuando así como asistente avanzado del gestor (OpenAI, 2025). Estos modelos también pueden resumir informes de mercado, filtrar noticias relevantes en tiempo real e incluso generar ideas de inversión a partir de datos no estructurados.

- Uso de datos alternativos y sensores inteligentes: los datos geoespaciales y de IoT están entrando en juego. Por ejemplo, hedge funds utilizan imágenes satelitales del tráfico en puertos y rutas comerciales para inferir la salud del comercio global o sensores IoT en buques para rastrear envíos de commodities en tiempo real. Estas señales facilitan el reequilibrio de portafolios de materias primas o divisas anticipándose a cambios en la oferta/demanda (Institutional Investor, 2016).

Otro caso es el monitoreo de datos medioambientales como emisiones de fábricas vía satélite que ciertos fondos ESG integran para ajustar la composición sectorial de sus carteras alineadas con sostenibilidad (Sokolov, Mostovoy, Ding, & Seco, 2021).

3.5. Barreras, desafíos y retos

La precisión predictiva se ha convertido en un factor competitivo clave en el sector y refleja un cambio significativo en la forma en que se abordarán las decisiones de inversión en el futuro. No obstante, a pesar de los beneficios de IA/ML en términos de precisión, su implementación en el sector financiero enfrenta un reto importante: la falta de interpretabilidad.

A diferencia de los modelos econométricos tradicionales, donde la contribución de cada variable es clara, muchos algoritmos de IA/ML funcionan como cajas negras, es decir, con una enorme dificultad en la explicación de sus decisiones. En un contexto tan sensible como las inversiones, esta opacidad puede ser problemática. Inversores y reguladores demandan poder entender los factores impulsores del rendimiento de una cartera (Banco de España, 2022).

Por ejemplo, si un modelo de IA propone una sobreponderación en cierto activo, el gestor debe justificar esa decisión ante el comité de inversiones o incluso clientes institucionales. Sin embargo, la naturaleza no lineal y adaptativa de modelos como los de Deep Learning dificulta trazar una relación simple de causa-efecto.

Las autoridades financieras siguen de cerca este desafío. Organismos como la Autoridad Bancaria Europea y BaFIN desde hace años realizan consultas sobre la regulación del uso de ML en modelos de capital regulatorio y procesos de toma de decisiones (Instituto de Finanzas Internacionales, 2020). La industria, a su vez, está adoptando técnicas de XAI (eXplainable AI) para mitigar estos problemas. Por ejemplo, se emplean modelos sustitutos más simples o métodos como Shapley values y LIME para estimar la contribución de cada variable a la decisión del modelo (Bartram, Branke, & Motahari, 2020).

El equilibrio entre desempeño predictivo contra explicabilidad se ha convertido en uno de los temas centrales: lograr modelos que aporten rentabilidad consistente pero que además puedan explicarse y auditarse es esencial para la adopción sostenible de la IA en finanzas.

Además, organismos como la IOSCO a nivel internacional han emitido alertas sobre otros posibles riesgos de la IA en finanzas. Desde potenciales sesgos discriminatorios hasta problemas de estabilidad si muchos actores usan algoritmos similares (IOSCO, 2025).

A su vez, otra barrera crítica es la escasez de talento especializado y el coste de infraestructura. Los llamados quantitative analysts/developers o científicos de datos

financieros son muy demandados y relativamente pocos. Las firmas de gestión de activos identifican esta falta de personal cualificado en IA/ML como un obstáculo importante para profundizar su adopción (Financial Services Skills Commission, 2024). Gestoras medianas y pequeñas encuentran difícil atraer profesionales con las habilidades híbridas de programación, estadística y conocimiento de mercados necesarias para desarrollar y mantener modelos de ML avanzados. A menudo terminan dependiendo de proveedores externos o plataformas de terceros, lo que puede ser costoso y crear dependencias. De hecho, mientras los grandes bancos y hedge funds pueden invertir cientos de millones en equipos de IA y servidores, muchos actores tradicionales tienen márgenes más ajustados que dificultan semejante gasto.

Concluyendo, la IA y el Machine Learning están transformando la optimización de carteras, aportando herramientas poderosísimas para extraer señales de datos masivos, construir carteras más eficientes y reaccionar con agilidad a las condiciones del mercado. Los casos de uso reales demuestran que, bien aplicada, esta tecnología puede mejorar rendimientos ajustados al riesgo y democratizar el acceso a estrategias sofisticadas. Aun así, su integración plena en el sector financiero necesita navegar desafíos técnicos, interpretativos y normativos.

A partir de este contexto tecnológico y práctico, es fundamental comprender los fundamentos teóricos que sustentan la optimización de carteras, que servirán de base para analizar y comparar distintos modelos posteriormente.

4. FUNDAMENTOS TEÓRICOS DE LA OPTIMIZACIÓN DE CARTERAS

4.1. Rentabilidad y riesgo

En la introducción se ha mencionado que el inversor toma decisiones buscando maximizar la rentabilidad al mismo tiempo que minimiza el riesgo. Este es un principio fundamental para todo agente racional.

Este comportamiento se puede explicar a través de las funciones de utilidad, herramientas matemáticas que permiten a los individuos evaluar y comparar distintos niveles de riqueza futura en presencia de incertidumbre.

Dado un conjunto de oportunidades de inversión, cada una de ellas está asociada a una distribución de posibles resultados aleatorios en términos de riqueza futura. En un escenario determinista, la decisión sería trivial: se elegiría la opción que garantizara la mayor riqueza final. Sin embargo, en un entorno incierto, los inversores requieren un criterio para comparar y seleccionar entre distintas alternativas. Es aquí donde las funciones de utilidad juegan un papel clave.

Formalmente, una función de utilidad $U(x)$ asigna un valor real a cada nivel posible de riqueza x . Dado un conjunto de alternativas de inversión con distribuciones de riqueza futuras representadas por variables aleatorias, los inversores comparan estas opciones mediante la esperanza matemática de la utilidad esperada, es decir, $E[U(x)]$. Una alternativa es preferida sobre otra si su utilidad esperada es mayor.

El grado de aversión al riesgo de un inversor depende de la forma específica de su función de utilidad. Un caso extremo es el de un individuo con una función de utilidad lineal $U(x) = x$, quien clasifica las opciones de inversión únicamente en función de su valor esperado, sin tomar en cuenta el riesgo. Este tipo de inversor es denominado neutral al riesgo. No obstante, la mayoría de los individuos exhiben aversión al riesgo, lo que se refleja en funciones de utilidad cóncavas. Cuanto mayor sea la curvatura de la función de utilidad, mayor será la aversión al riesgo (Luenberger, 1998).

Para cuantificar esta aversión, se emplea el coeficiente de aversión absoluta al riesgo de Arrow-Pratt, definido como:

$$a(x) = -\frac{U''(x)}{U'(x)}$$

donde:

- $U'(x)$ representa la utilidad marginal de la riqueza, y
- $U''(x)$ indica la concavidad de la función de utilidad.

Este coeficiente mide cómo cambia la aversión al riesgo en función del nivel de riqueza. En general, se observa que a medida que la riqueza de un individuo aumenta, su aversión al riesgo tiende a disminuir. Esto pone de manifiesto el comportamiento intuitivo de que los individuos con mayor seguridad financiera están dispuestos a asumir mayores riesgos en sus decisiones de inversión.

El riesgo y la rentabilidad son los componentes básicos de la gestión financiera y de la cartera de valores. Una vez que se han especificado el riesgo y la rentabilidad esperada, la moderna teoría financiera puede ayudar a los inversores a asignar activos a sus carteras de manera eficiente.

Para muchos inversores, el modo más intuitivo de describir el riesgo es mediante la representación del escenario más desfavorable. Esta forma de abordar el riesgo es conocida como Value at Risk (VaR), una métrica estadística que estima las pérdidas potenciales de una cartera o posición durante un horizonte temporal específico (Kenton, 2024). No obstante, no es objetivo de este trabajo analizar este concepto y tomarlo como referencia para medir el riesgo. Por ahora, es importante señalar que la teoría moderna de carteras emplea la desviación estándar como medida principal de este, ya que refleja la volatilidad de los rendimientos de los activos y, por ende, la incertidumbre inherente en las decisiones de inversión.

4.2. Correlación y diversificación

Un concepto clave es entender cómo el riesgo y la rentabilidad de una cartera dependen del comportamiento de sus activos individuales y cómo la diversificación puede mejorar la eficiencia de la inversión.

Supongamos que tenemos una cartera de N activos, donde:

- S_i representa el valor inicial del activo i
- R_i es su rentabilidad aleatoria en un horizonte temporal T , que se modela como una variable normalmente distribuida con media $\mu_i T$ y desviación estándar $\sigma_i \sqrt{T}$, donde μ_i es la tasa de rentabilidad esperada por unidad de tiempo y σ_i su volatilidad por unidad de tiempo.
- La correlación entre dos activos i y j se denota como ρ_{ij} , donde $\rho_{ii} = 1$

El valor total de la cartera en el instante inicial es:

$$P_0 = \sum_{i=1}^N W_i S_i$$

y al final del periodo:

$$P_T = \sum_{i=1}^N W_i S_i (1 + R_i)$$

donde W_i representa el peso de cada activo en la cartera.

El rendimiento esperado de la cartera es:

$$\mu_P = \sum_{i=1}^N W_i \mu_i$$

y su volatilidad (desviación estándar) se calcula como:

$$\sigma_P = \sqrt{\sum_{i=1}^N \sum_{j=1}^N W_i W_j \rho_{ij} \sigma_i \sigma_j}$$

Estos parámetros posibilitan relacionar el riesgo y la rentabilidad de la cartera con los de sus activos individuales.

Si los activos en la cartera no están correlacionados ($\rho_{ij} = 0$ para $i \neq j$) y tienen pesos iguales ($W_i = \frac{1}{N}$), entonces se observa fácilmente que:

- La rentabilidad esperada sigue siendo el promedio de los rendimientos individuales:

$$\mu_P = \frac{1}{N} \sum_{i=1}^N \mu_i$$

- La volatilidad de la cartera se reduce con el número de activos según la proporción $O\left(\frac{1}{\sqrt{N}}\right)$:

$$\sigma_P = \sqrt{\frac{1}{N^2} \sum_{i=1}^N \sigma_i^2}$$

Si a medida que N crece la volatilidad disminuye, significa que, al diversificar, se reduce el riesgo sin afectar el rendimiento.

Este principio es la base de la gestión de carteras: no poner todos los huevos en la misma cesta.

4.3. Teoría de cartera media-varianza de Markowitz

Con el marco planteado, se puede analizar la mejor cartera posible. El contenido de esta sección está guiado principalmente por los apartados 21.3 y 21.4 del libro *Paul Wilmott Introduces Quantitative Finance* (Wilmott, 2007).

El concepto de cartera óptima fue desarrollado por Harry Markowitz, quien introdujo el criterio de eficiencia media-varianza. Este criterio establece que una cartera es eficiente si logra minimizar el riesgo para un nivel específico de rentabilidad esperada, o lo que es lo mismo, maximizar la rentabilidad esperada para un nivel dado de riesgo.

Es decir, una cartera P^* será eficiente si no existe otra combinación de activos que ofrezca una mayor rentabilidad esperada con el mismo o menor nivel de riesgo. Esta es la base de la teoría moderna de carteras (MPT).

Para entenderlo mejor se considera el caso de cuatro activos: A, B, C y D, cada uno con un nivel de rentabilidad y riesgo específicos, como se muestra en la figura 2 (sin tener en cuenta el activo E por ahora).

Si solo se pudiera elegir uno de estos activos, ¿cuál sería la mejor opción? Empezando con D, aunque tiene el mismo nivel de riesgo que B, su rentabilidad es menor, lo que lo hace menos atractivo. De manera similar, aunque D tiene la misma rentabilidad que C, su riesgo es más alto, lo que también lo convierte en una opción menos favorable. Por lo tanto, se puede descartar a D.

Ahora, al comparar B y C, ambos activos parecen mejores que D, pero la decisión no es tan clara. B tiene un mayor riesgo, pero a cambio ofrece una rentabilidad más alta. Por otro lado, C presenta un equilibrio más conservador entre riesgo y rentabilidad, lo que podría atraer a un inversor más prudente. Sin embargo, cuando los comparamos con A, la elección se vuelve mucho más evidente. A ofrece una rentabilidad interesante con un nivel de riesgo más bajo que B, siendo así una opción preferida.

Al introducir el activo E, que tiene el mismo nivel de riesgo que B pero ofrece una rentabilidad superior a la de A, la decisión se complica. ¿Es mejor A o E? No hay una respuesta clara, ya que depende de las preferencias de riesgo de cada inversor. Si un inversor prefiere una mayor rentabilidad y está dispuesto a asumir más riesgo, podría elegir E. Si, en cambio, busca una opción más segura con una rentabilidad aceptable, A sería la opción preferible.




Figura 2. Rentabilidad y riesgo para cinco activos

Fuente: (Wilmott, 2007)

Considerando la combinación de los activos A y E, el comportamiento de la relación riesgo/recompensa del portafolio resultante dependerá de la ponderación asignada a cada activo, denotada como W , que representa el peso del activo A en el portafolio. Dado que el peso total debe sumar 1, el peso del activo E será $1 - W$. A medida que varíe W , el riesgo y la rentabilidad del portafolio cambiarán en función de cómo se combinan las características de A y E.

En este caso, la rentabilidad esperada del portafolio μ , se obtiene como una combinación ponderada de las rentabilidades de los activos A y E, como muestra la ecuación:

$$\mu = W\mu_A + (1 - W)\mu_E$$

Mientras que el riesgo del portafolio, representado por la varianza σ^2 , depende de las varianzas individuales de los activos, sus covarianzas y la correlación entre ellos. La fórmula para la varianza del portafolio es:

$$\sigma^2 = W^2\sigma_A^2 + 2W(1 - W)\rho\sigma_A\sigma_E + (1 - W)^2\sigma_E^2$$

Aquí, σ_A y σ_E son las volatilidades de los activos A y E, respectivamente, y ρ es la correlación entre ellos. Esta fórmula recuerda cómo la combinación de ambos activos

genera un riesgo total que no es simplemente la suma de los riesgos individuales, sino que también está influenciado por la interacción entre los dos activos.

Al variar el peso W , se genera una curva en el espacio de riesgo/recompensa, representada como una hipérbola, como se muestra en la figura 3. En esta curva, la parte en negrita, denominada frontera eficiente, representa las combinaciones de activos que ofrecen el mayor rendimiento posible para cada nivel de riesgo, o el menor riesgo para un nivel de rendimiento dado. La elección de la posición en esta curva depende de las preferencias de riesgo del inversor. Un inversor más conservador podría preferir una combinación con menor riesgo, mientras que uno más arriesgado podría optar por una mayor rentabilidad, aceptando más volatilidad.




Figura 3. Dos activos y sus combinaciones

Fuente: (Wilmott, 2007)

Cuando se considera un portafolio con más de dos activos, como A, B, C, D y E, la representación gráfica de las combinaciones de riesgo y recompensa ya no se limita a una simple hipérbola, sino que se forma una superficie de posibles combinaciones, como se observa en la figura 4. Aunque algunos activos como B, C y D pueden no ser atractivos por sí solos, pueden contribuir a la diversificación del portafolio, dependiendo

de cómo se correlacionen con los otros activos. En esta figura, la frontera eficiente está marcada en negrita, y cualquier portafolio óptimo debe estar en esta frontera.




Figura 4. Posibilidades de un portafolio y la frontera eficiente

Fuente: (Wilmott, 2007)

Si se añade un activo libre de riesgo con una rentabilidad garantizada r (como un bono del gobierno con rendimiento fijo), este aparecerá como el punto F en la figura 4. Al permitir la inclusión de este activo en el portafolio, la nueva frontera eficiente se convierte en una línea recta, conocida como línea del mercado de capitales (CML, por sus siglas en inglés). El punto donde esta línea recta toca la frontera eficiente original es el portafolio de mercado, que representa una combinación óptima de activos de riesgo en términos de rentabilidad y volatilidad.

Aunque la frontera eficiente es un concepto objetivo basado en datos concretos, la elección del portafolio ideal dentro de esta frontera es subjetiva y como se ha dicho depende de las preferencias individuales del inversor.

Uno de los métodos más utilizados para seleccionar el portafolio óptimo es a través de un concepto que se ha introducido previamente, la función de utilidad. Mediante esta metodología las preferencias del inversor son representadas en términos de su

tolerancia al riesgo y su deseo de maximizar la rentabilidad. Las curvas de indiferencia representan combinaciones de riesgo y rentabilidad entre las cuales el inversor es indiferente, es decir, cualquier portafolio situado en la misma curva le proporciona el mismo nivel de satisfacción.

En un gráfico donde se representa la frontera eficiente junto con las curvas de indiferencia, se observa que distintos portafolios presentan diferentes niveles de riesgo y rentabilidad. En la figura 5 un hipotético inversor enfrenta decisiones como las siguientes:

- Portafolio A: Bajo riesgo y baja rentabilidad.
- Portafolio B: Mayor riesgo, pero con una rentabilidad más atractiva.
- Portafolio C: Situado en una curva de indiferencia superior, lo que indica que proporciona un mejor equilibrio entre riesgo y rentabilidad en comparación con A y B.




Figura 5. La frontera eficiente y curvas de indiferencia

Fuente: (Wilmott, 2007)

Dado que cada inversor tiene una aversión al riesgo diferente, la selección del portafolio óptimo dependerá de su disposición a asumir volatilidad a cambio de mayor rentabilidad

esperada. En general, el mejor portafolio será aquel que, dentro de la frontera eficiente, se ubique en la curva de indiferencia más alta posible para el inversor.

4.4. Benchmark y retorno residual

Una extensión del modelo clásico de eficiencia media-varianza (MV) de Markowitz es la optimización basada en un benchmark, la cual se fundamenta en el concepto de retorno residual. Este retorno residual se define como la diferencia entre el retorno de un activo y el retorno de un benchmark de referencia (Michaud & Michaud, 2008).

Para analizar esta variante, es útil definir las siguientes métricas:

- α : Retorno residual esperado, que representa la expectativa del exceso de retorno de un activo o cartera con respecto a su benchmark.
- ω^2 : Varianza del retorno residual, que mide la volatilidad de esta diferencia de retornos.

Bajo este marco, la eficiencia de Markowitz para el retorno residual sigue los mismos principios que en el caso tradicional, pero reemplazando la rentabilidad esperada μ y la varianza σ^2 por α y ω^2 , respectivamente.




Figura 6. Riesgo residual y eficiencia del retorno del portafolio

Fuente: (Michaud & Michaud, 2008)

Por definición, el benchmark tiene un retorno residual esperado nulo y un riesgo residual igual a cero. En muchas aplicaciones, este punto de referencia puede ser un índice de mercado ampliamente utilizado, como el S&P 500.

En la Figura 6 un hipotético inversor con la cartera A busca optimizar el retorno residual esperado manteniendo el mismo nivel de riesgo residual. La figura supone que el rendimiento del benchmark es un portafolio factible dentro del conjunto de oportunidades de inversión. La frontera eficiente en este contexto está formada por todas las carteras que maximizan el retorno residual esperado para cada posible nivel de riesgo residual.

Es importante señalar que el punto (0,0), correspondiente al benchmark, se encuentra también sobre la frontera eficiente, aunque representa un caso trivial: al no asumir ningún riesgo residual respecto a sí mismo, su retorno residual esperado es necesariamente nulo. El benchmark actúa como referencia desde la cual los inversores buscan mejorar el retorno ajustado al riesgo. En este sentido, las carteras activas eficientes se sitúan por encima del benchmark en el eje vertical del gráfico. La frontera eficiente, por tanto, se interpreta como el conjunto de carteras que logran el máximo exceso de retorno esperado (α) para cada nivel posible de varianza residual (ω^2). Así, el gestor evalúa si su cartera actual (como el punto A en la figura) está infrautilizando su exposición activa y qué mejora sería factible dentro del mismo nivel de riesgo residual.

4.5. El equilibrio de mercado

Dentro del marco de la teoría media-varianza de Markowitz, si todos los inversores optimizan sus carteras basándose en este criterio y comparten las mismas expectativas sobre la distribución de rendimientos, varianzas y covarianzas de los activos, se alcanza de forma natural una única estructura de inversión. Esto sucede porque, en ausencia de costes de transacción y con un único activo libre de riesgo accesible para todos, la construcción óptima de la cartera consiste en combinar un fondo de activos arriesgados con el activo libre de riesgo.

Este fenómeno es explicado por el teorema de un solo fondo, que establece que todos los inversores mantendrán una proporción de sus recursos en el mismo portafolio eficiente de activos arriesgados, ajustando su exposición al riesgo solo por la cantidad invertida en el activo libre de riesgo. Los inversores más adversos al riesgo asignarán una mayor proporción de su cartera a este activo seguro, mientras que los más tolerantes al riesgo aumentarán su participación en el fondo de activos arriesgados e incluso podrían apalancarse para aumentar su exposición (Luenberger, 1998).

Si todos los inversores eligen el mismo fondo de activos arriesgados y la suma total de sus inversiones coincide con el valor total del mercado, la única solución coherente en equilibrio es que dicho fondo sea el portafolio de mercado. Es decir, la combinación óptima de activos de riesgo que seleccionan los inversores reflejará la capitalización bursátil de cada activo en el mercado total.

Este razonamiento es esencial para el desarrollo del Capital Asset Pricing Model (CAPM), ya que implica que la mejor estrategia para cualquier inversor, dadas estas condiciones, es replicar el portafolio de mercado. Como todos los activos deben ser mantenidos por alguien, la ponderación de cada activo en este portafolio se determina de forma endógena, según su valor total de mercado en relación con el valor total de todos los activos.

El concepto de equilibrio se basa en la interacción de oferta y demanda en el mercado. En un entorno donde todos los inversores intentan optimizar sus carteras de acuerdo con la misma metodología, la formación de precios es crucial para que se logre el equilibrio hacia el portafolio de mercado.

Si la demanda por ciertos activos excede la oferta disponible en el mercado, sus precios aumentarán, mientras que aquellos con menor demanda verán una caída en su cotización. Además, como los precios afectan directamente la rentabilidad esperada de los activos, los inversores ajustarán sus estimaciones y modificarán sus decisiones de inversión. A medida que los precios se ajustan y los inversores recalculan sus portafolios óptimos, el mercado tiende hacia un estado de equilibrio donde la demanda por cada activo iguala la oferta disponible.

Este proceso no requiere que todos los inversores realicen cálculos de optimización de manera constante. En la práctica, bastará con que algunos agentes activos realicen estos ajustes y que el resto del mercado siga sus movimientos, adoptando pasivamente el portafolio de mercado. Esta idea es consistente con la observación empírica de que muchos inversores optan por estrategias pasivas, como replicar índices de mercado, reforzando de esta manera la eficiencia del portafolio agregado.

No obstante, aunque la teoría es elegante en su formulación, en la realidad hay diversas razones por las que el mercado puede desviarse de este equilibrio teórico:

- Diferencias en expectativas: En la práctica, los inversores no comparten exactamente las mismas proyecciones sobre retornos, varianzas y covarianzas (Adam & Nagel, 2022).

- Restricciones de inversión: Factores como costes de transacción, regulaciones y limitaciones de liquidez impiden la plena diversificación.
- Presencia de inversionistas no racionales: No todos los agentes del mercado siguen un enfoque media-varianza. Muchos operan bajo heurísticas o con información imperfecta (Benartzi & Thaler, 2001) (Kahneman & Tversky, 1979).
- Riesgo idiosincrático y preferencias personales: Algunos inversores pueden preferir estrategias activas, seleccionando activos específicos basados en creencias individuales o necesidades específicas (Kumar & Goetzmann, 2008).

A pesar de estas limitaciones, el portafolio de mercado sigue siendo una referencia clave para la construcción de carteras eficientes.

5. MÉTODOS BASADOS EN APRENDIZAJE PROFUNDO

En la gestión de carteras, el aprendizaje profundo se propone como una alternativa poderosa frente a las herramientas tradicionales que suponen relaciones esencialmente lineales. A diferencia de los modelos clásicos, las redes profundas pueden descubrir dinámicas más ricas.

Numerosos estudios han explorado desde la predicción de precios y señales de trading, hasta la construcción y rebalanceo dinámico de carteras. Un beneficio clave es que las redes profundas pueden, en principio, aprender automáticamente características relevantes de los datos (por ejemplo, identificar patrones temporales o combinaciones de factores) sin requerir la especificación manual de todos los factores explicativos. Esto supera la dependencia en supuestos simplificadores de muchos modelos convencionales.

A continuación, se presenta una descripción de las principales arquitecturas de Deep Learning aplicadas a la optimización de carteras.

5.1. Redes neuronales profundas (Deep Neural Networks, DNN)

Las redes neuronales profundas de tipo feedforward son la forma canónica de Deep Learning. Consisten en capas múltiples de neuronas artificiales organizadas secuencialmente, donde cada neurona combina linealmente las salidas de la capa anterior y aplica una función de activación no lineal (Wüthrich & Merz, 2022). El resultado es una función altamente flexible capaz de aproximar prácticamente cualquier relación no lineal entre las variables de entrada (por ejemplo, características macroeconómicas, precios pasados de activos, etc.) y las variables de salida (por ejemplo, el retorno futuro esperado de un activo o su riesgo).

En el contexto de carteras, las DNN suelen utilizarse para predicción de retornos o riesgos a partir de un amplio conjunto de factores. Por ejemplo, en la optimización de carteras de acciones, se pueden usar redes profundas para estimar la prima esperada de cada acción dada cierta información histórica y fundamental y luego alimentar esas estimaciones a un modelo de asignación óptima de pesos.

Un estudio comparó numerosos métodos de Machine Learning para estimar los rendimientos esperados de acciones individuales, encontrando que los métodos más potentes, incluyendo bosques aleatorios y redes neuronales profundas, doblaban el desempeño de las regresiones lineales tradicionales, gracias a que capturan interacciones no lineales entre predictores que los modelos lineales pasan por alto (Gu,

Kelly, & Xiu, 2019). En otras palabras, las DNN pueden detectar combinaciones de señales (momentum, liquidez, volatilidad implícita, etc.) cuya relación con los retornos es compleja y mejorar así las estimaciones de retorno utilizado para formar carteras eficientes.

La aplicación de redes profundas a la construcción de portafolios puede hacerse de dos modos principales:

- De forma indirecta: la red predice parámetros (retornos esperados, covarianzas, betas, etc.) que luego se introducen en un modelo de optimización como la media-varianza.
- De forma directa: la propia red aprende a generar la asignación de pesos óptima en la cartera como salida, dado el estado actual del mercado como entrada.

Un ejemplo notable del enfoque directo lo aporta un estudio donde se diseñó una red neuronal profunda entrenada para optimizar directamente la relación rentabilidad-riesgo de una cartera en el proceso de entrenamiento, evitando así tener que predecir retornos explícitamente (Zhang, Zohren, & Roberts, 2021). En ese estudio, en lugar de seleccionar activos individuales, la red ajustaba dinámicamente los pesos asignados a ETFs representativos de índices de mercado y aprendía gradualmente la mejor combinación de activos. Los resultados mostraron que dicho modelo de fin a fin superaba a numerosos algoritmos de referencia en el período de prueba, incluso durante episodios de alta volatilidad como la crisis de la pandemia de 2020.

Desde el punto de vista formal, una DNN se entrena minimizando una función de pérdida apropiada (por ejemplo, el error cuadrático en la predicción de retornos, o una pérdida personalizada que refleje la utilidad del inversor) mediante algoritmos de gradiente descendente y backpropagation. La complejidad del modelo (número de capas, neuronas y parámetros) se ajusta para equilibrar la capacidad de aprendizaje de relaciones complejas con el riesgo de sobreajuste a datos históricos particulares.

En finanzas, suele ser necesario regularizar las redes y validarlas rigurosamente con datos fuera de muestra, dado el peligro de encontrar patrones engañosos en series financieras limitadas. Aun así, cuando se dispone de datos suficientes, las DNN han mostrado poder capturar efectivamente no linealidades útiles.

5.2. Redes neuronales recurrentes

Para problemas con datos secuenciales en el tiempo, típicamente series temporales financieras, una arquitectura adecuada es la de redes neuronales recurrentes (RNN). Estas redes incorporan conexiones recurrentes que les permiten conservar un estado

interno o memoria de corto y largo plazo, actualizada a medida que avanza la secuencia temporal (Hewamalage, Bergmeir, & Bandara, 2020). De este modo, son capaces de modelar dependencias dinámicas: por ejemplo, capturar patrones de autocorrelación, tendencias persistentes o reversiones a la media en precios y retornos de activos a lo largo del tiempo.

Dentro de las RNN, una variante destacada es la de unidades de memoria de largo corto plazo, conocidas como LSTM (Long Short-Term Memory), introducidas para superar problemas de las RNN simples y permitir el aprendizaje de dependencias a más largo plazo.

En el contexto de la optimización de carteras, las redes LSTM se utilizan principalmente para pronosticar variables financieras temporales que luego alimentan las decisiones de inversión. En 2018 se realizó un estudio pionero aplicando LSTM a la predicción de movimientos direccionales diarios en los 500 componentes del S&P 500 a lo largo de más de 20 años (Fischer & Krauss, 2018). Sus resultados mostraron que la LSTM superaba significativamente a métodos de clasificación "sin memoria" como bosques aleatorios, redes profundas feedforward tradicionales o regresiones logísticas.

La ventaja de la LSTM proviene de su capacidad para recordar patrones temporales de los precios como por ejemplo episodios de reversiones cortas o continuaciones de tendencia.

En la selección de activos, una LSTM podría analizar simultáneamente múltiples series de precios de distintos activos y detectar, por ejemplo, qué activos tienden a liderar movimientos de mercado o cuáles presentan patrones diferenciados. Esto ayudaría a tomar decisiones como sobreponderar ciertos activos o sectores en el portafolio, especialmente si la LSTM predice las rentabilidades futuras.

Además de la predicción de retornos, las redes LSTM se han aplicado a la predicción de la volatilidad y otros riesgos financieros. Tradicionalmente, la volatilidad se modelaba con procedimientos estadísticos como GARCH, pero las RNN ofrecen un enfoque no paramétrico alternativo. Estudios recientes indican que modelos híbridos que combinan LSTM con enfoques GARCH mejoran la precisión pronosticando volatilidad a mediano y largo plazo (Yang, Ye, & Zhai, 2024). Desde la perspectiva de la optimización de carteras, contar con pronósticos más exactos de volatilidad o correlaciones dinámicas es realmente valioso, ya que permite ajustar la composición del portafolio para controlar el riesgo de manera más proactiva.

5.3. Redes de Aprendizaje por Refuerzo Profundo (Deep Reinforcement Learning)

El aprendizaje por refuerzo profundo traslada la optimización de carteras a un problema dinámico de control secuencial.

Formalmente, la gestión de la cartera se modela como un proceso definido por el conjunto de componentes (S, A, P, r, γ) , donde:

- S es el conjunto de estados del sistema, que en este contexto representa la información observable del mercado en un momento dado: precios de activos, indicadores técnicos, posiciones actuales, etc.
- A es el conjunto de acciones posibles, que corresponden a las decisiones del agente, como la asignación de pesos a los distintos activos de la cartera.
- $P(s' | s, a)$ es la función de transición de estados, que describe la probabilidad de pasar al estado s' en el siguiente instante, dado el estado actual s y la acción tomada a .
- $r(s, a)$ es la función de recompensa, que asigna un valor numérico a la acción tomada en cierto estado, reflejando el rendimiento o utilidad que recibe el agente. Por ejemplo, puede definirse como el log-retorno de la cartera ajustado por riesgo.
- $\gamma \in (0,1)$ es el factor de descuento, que pondera la importancia de las recompensas futuras frente a las inmediatas.

El agente aprende una política, parametrizada por una red profunda, que maximiza el valor descontado esperado (Jiang, Xu, & Liang, 2017).

La clave es que la política se ajusta tras cada observación del mercado, de modo que la cartera se rebalancea de forma adaptativa conforme cambian las condiciones, algo imposible con la frontera media-varianza tradicional.

Las investigaciones recientes se centran en métodos actor-critic, que combinan dos componentes: uno que toma decisiones (actor) y otro que evalúa si han sido buenas o malas (critic). Esta aproximación ayuda a que el aprendizaje sea más estable. Entre estos métodos, Proximal Policy Optimization (PPO) destaca por ser fácil de implementar y por mantener cambios suaves en la política del agente, lo que mejora la estabilidad del entrenamiento (Schulman, Wolski, Dhariwal, Radford, & Klimov, 2017). Además, en entornos donde las decisiones no son discretas sino continuas, como asignar porcentajes a cada activo, se usan variantes como DDPG y TD3, que permiten al agente

aprender acciones precisas en escenarios más realistas y complejos (Lillicrap, y otros, 2019) (Fujimoto, Hoof, & Meger, 2018).

Más allá de los modelos monolíticos, el Aprendizaje por Refuerzo Jerárquico (HRL) divide la tarea en decisiones tácticas (selección de activos) y operativas (ejecución). El esquema Hierarchical Reinforced Trader integra un controlador de alto nivel basado en PPO para escoger los activos y un DDPG de bajo nivel para dosificar las órdenes. En pruebas sobre el S&P 500 el marco jerárquico mejoró la optimización rentabilidad-riesgo y redujo el sobre-trading respecto a agentes planos y al índice de referencia (Zhao & Welsch, 2024).

5.4. Otros métodos avanzados: Autoencoders y Transformers

En la literatura reciente sobre Deep Learning para gestión de carteras se han popularizado dos familias adicionales de arquitecturas, Autoencoders y Transformers, que cumplen funciones complementarias a los modelos supervisados y por refuerzo ya descritos.

Los Autoencoders son redes neuronales profundas que se entrenan de forma no supervisada con el objetivo de reconstruir su propia entrada. Para ello, comprimen la información en una capa intermedia de menor dimensión, denominada capa latente, que actúa como una representación compacta de los datos originales.

Una versión simple de Autoencoder lineal es matemáticamente equivalente al Análisis de Componentes Principales (PCA, por sus siglas en inglés), una técnica estadística utilizada para reducir la dimensionalidad de los datos extrayendo las direcciones (componentes principales) que capturan mayor varianza. En cambio, los Autoencoders profundos permiten capturar factores latentes no lineales.

En gestión de carteras se emplean, sobre todo, para descubrir factores de mercado y para réplica de índices (index tracking). Al entrenarse con los retornos de todos los componentes de un índice, la red aprende qué activos son más representativos. Seleccionar los títulos con menor error de reconstrucción permite formar carteras reducidas con bajo tracking error, es decir, que replican muy de cerca el comportamiento del índice original, pero con menos activos y menores costes de transacción. Estudios recientes demuestran que arquitecturas como los Autoencoders esparsos, denoising o variacionales mejoran sistemáticamente el seguimiento del índice frente a métodos tradicionales de selección por capitalización o correlación directa (Zhang, Liang, Lyu, & Fang, 2020).

La arquitectura Transformer, impulsada por la atención autorregresiva, se ha trasladado al asset allocation para modelar dependencias temporales largas y relaciones cruzadas entre activos. A diferencia de las RNN, la atención pondera simultáneamente distintos momentos o señales, lo que facilita al modelo identificar patrones de largo alcance relevantes para predecir retornos, volatilidad o correlaciones. La investigación actual explora variantes híbridas que combinan un bloque Transformer con un módulo de optimización clásica para capitalizar la potencia de la atención sin renunciar al control explícito del riesgo (Ma, Wang, & Chen, 2023) (Chandrasekaran, Sharma, & Sai, 2024).

En síntesis, el rápido avance del Deep Learning ha ampliado de forma decisiva el repertorio de técnicas disponibles para la optimización de carteras. Todo esto representa un salto cualitativo para la gestión cuantitativa de carteras al permitir un análisis más rico, adaptable y multidimensional del mercado. Sus ventajas (mayor poder predictivo, integración de datos alternativos y optimización de objetivos complejos) son particularmente valiosas cuando las simplificaciones lineales del enfoque de Markowitz resultan insuficientes.

En las próximas secciones, algunas de estas arquitecturas de aprendizaje profundo se trasladarán a un contexto práctico de optimización de carteras, no sin antes implementar el modelo tradicional de Markowitz.

6. EL MODELO DE MARKOWITZ EN LA PRÁCTICA

En esta sección se lleva a la práctica el modelo de cartera media-varianza desarrollado por Harry Markowitz. El objetivo principal es aplicar esta metodología a un conjunto específico de activos e identificar la cartera óptima a través de la construcción de la frontera eficiente.

6.1. Universo de inversión

El universo de inversión seleccionado para el presente estudio, es decir tanto para este caso donde se implementa el modelo de Markowitz como en los posteriores donde se utilizará aprendizaje profundo, comprende un conjunto diversificado y representativo de activos financieros y reales.

Concretamente, el universo elegido está compuesto por las siguientes acciones: Google (GOOGL), Berkshire Hathaway (BRK-B), Microsoft (MSFT), Apple (AAPL), Johnson & Johnson (JNJ), Alibaba (BABA), ASML, McDonald's (MCD), UnitedHealth Group (UNH), Tesla (TSLA), Banco Santander (SAN), Amazon (AMZN), y LVMH Moët Hennessy Louis Vuitton (MC.PA). Además, se incorporan dos activos reales, Bitcoin (BTC-USD) y el oro (GC=F), con el propósito específico de ampliar las opciones de diversificación más allá del mercado de valores tradicional.

La elección de este conjunto de activos, aunque arbitraria, está cuidadosamente fundamentada en criterios estratégicos clave:

- Diversificación geográfica: Incluye activos provenientes de diferentes regiones económicas importantes: Estados Unidos, Europa y China. De este modo será posible capturar comportamientos diversos y no necesariamente altamente correlacionados para contribuir a la diversificación de la cartera.
- Diversificación sectorial: Los activos seleccionados abarcan múltiples sectores industriales, tecnológicos, financieros, de consumo, salud y lujo, dando pie a una reducción adicional del riesgo específico asociado a cualquier sector individual.
- Alta capitalización bursátil: Todos los activos seleccionados cuentan con una gran capitalización bursátil para garantizar mayor estabilidad, mejor liquidez y transparencia en los mercados financieros.
- Incorporación de activos reales: La inclusión de Bitcoin y el oro busca ofrecer exposición a clases de activos alternativas a los mercados accionarios tradicionales.

6.2. Implementación del modelo de optimización media-varianza

Para implementar el modelo de optimización media-varianza en la práctica, se sigue un procedimiento estructurado donde se define la tasa libre de riesgo, se construye la frontera eficiente y, finalmente, se determina el portafolio óptimo o portafolio tangente, punto donde la línea del mercado de capitales es tangente a la frontera eficiente.

Para una visión detallada del proceso de implementación, se incluye en el Anexo I el código completo utilizado para construir y evaluar el modelo de Markowitz.

6.2.1. Datos y pasos previos

La información histórica de precios que se utiliza en todo el estudio, tanto para este modelo como para los posteriores, abarca desde el 1 de enero de 2015 hasta el 31 de diciembre de 2024, dividiendo este periodo en tres subconjuntos clave:

- Conjunto de entrenamiento: del 1 de enero de 2015 al 31 de diciembre de 2021.
- Conjunto de validación: año 2022 (solo utilizado posteriormente en uno de los modelos de Deep Learning).
- Conjunto de prueba (test): del 1 de enero de 2023 al 31 de diciembre de 2024.

En el caso de uno de los modelos de Deep Learning que se analizará después, el año 2022 se reserva como conjunto de validación. Por este motivo, el entrenamiento de estos modelos se limita a datos hasta el cierre de 2021.

Aunque el modelo clásico de Markowitz no requiere validación explícita, se ha decidido mantener la coherencia en los conjuntos de entrenamiento para asegurar una comparación justa entre métodos. En consecuencia, 2022 también se excluye del entrenamiento del modelo de Markowitz y así se garantiza igualdad de condiciones en la evaluación de rendimiento sobre el mismo conjunto de test (2023-2024).

En este caso, la implementación se lleva a cabo en R. Se utilizan varios paquetes especializados que facilitan la manipulación, análisis y visualización de series temporales financieras. El paquete `quantmod` se emplea para la descarga de datos históricos desde fuentes como Yahoo Finance. Por otra parte, `timeSeries` permite convertir los datos a un formato compatible con los métodos financieros utilizados y `fPortfolio` es el encargado de construir y optimizar carteras bajo el marco de media-varianza de Markowitz. Para el análisis posterior del rendimiento y el riesgo de dichas carteras, se utiliza `PerformanceAnalytics`, que incluye herramientas para evaluar

métricas como el ratio de Sharpe o la volatilidad anualizada. Además, ggplot2 se usa para generar gráficos claros y personalizados que acompañan visualmente el análisis cuantitativo.

Para cada valor del universo de inversión se descargan los precios de cierre ajustados P_t y se transforman en rendimientos discretos:

$$r_t = \frac{P_t - P_{t-1}}{P_{t-1}}$$

El resultado se guarda como un objeto xts y, más tarde, como timeSeries, formato requerido por fPortfolio.

El modelo necesita un activo exento de riesgo para trazar la Línea del Mercado de Capitales (CML). Para ello, se emplea como aproximación la rentabilidad del bono estadounidense a 10 años (GS10). La tasa libre de riesgo se estima como la media aritmética anual de los valores diarios de GS10 durante el periodo 2015-2024, que se obtiene directamente desde la base de datos FRED. Esta media se divide entre 252 para convertirla a base diaria y utilizarla en coherencia con los retornos diarios del resto de activos. Calcularla sobre todo el periodo garantiza una estimación más estable y representativa del coste de oportunidad sin riesgo. Aunque en ciertos contextos la media geométrica puede ser preferible por reflejar mejor el crecimiento compuesto, en este caso no es necesaria dada la naturaleza estática y comparativa del análisis.

6.2.2. Generación de la frontera eficiente

Se impone que se trabajará únicamente con posiciones largas, es decir, sin posiciones cortas.

A continuación, portfolioFrontier() resuelve (para cada nivel de riesgo objetivo σ^2) el problema:

$$\max \boldsymbol{\mu}^T \mathbf{w} \quad \text{s.a. } \mathbf{w}^T \boldsymbol{\Sigma} \mathbf{w} \leq \sigma^2, \quad \mathbf{1}^T \mathbf{w} = 1, \quad \mathbf{w} \geq 0$$

donde $\boldsymbol{\mu}$ es el vector de rentabilidades medias por activo, $\mathbf{w}$ es el vector de pesos de inversión asignados a cada uno de los activos con riesgo y $\boldsymbol{\Sigma}$ la matriz de covarianzas entre dichos activos, todos ellos estimados a partir del conjunto de entrenamiento. Cabe destacar que el activo libre de riesgo no forma parte de esta optimización, por lo que no recibe ningún peso en la construcción de las carteras eficientes. La frontera eficiente generada es la siguiente:




Figura 7. Frontera eficiente de la optimización media-varianza de Markowitz

Fuente: Elaboración propia

En la gráfica se muestra la relación riesgo-rentabilidad de todas las carteras que el optimizador ha calculado con los datos de entrenamiento.

Los puntos negros representan las carteras eficientes formadas por combinaciones de activos con riesgo. Para cada valor de riesgo (eje X) no existe otra combinación que ofrezca una rentabilidad media superior (eje Y). Conformen, por tanto, la frontera eficiente.

Los puntos grises señalan carteras ineficientes. Presentan la misma o una mayor volatilidad que alguna cartera situada sobre la frontera eficiente, pero con un rendimiento esperado más bajo. Por ello, quedan descartadas desde el punto de vista de la optimización media-varianza.

El punto rojo corresponde a la cartera de mínima varianza global (Global Minimum Variance, GMV). Es la combinación de activos con el menor nivel de riesgo posible.

El triángulo azul marca la cartera tangente. Esta cartera maximiza el ratio de Sharpe, es decir, logra la mayor rentabilidad adicional por unidad de riesgo. En términos geométricos, corresponde al punto de tangencia entre la Línea del Mercado de Capitales (trazada desde la tasa libre de riesgo) y la frontera eficiente.

La línea azul es la Línea del Mercado de Capitales (CML). Cualquier combinación situada sobre esta recta puede interpretarse como una mezcla entre el activo libre de riesgo y la cartera tangente, variando la exposición según la aversión al riesgo del inversor.

6.2.3. Configuración y pesos de los activos en la cartera óptima

Se selecciona la cartera tangente, es decir las coordenadas del triángulo azul, para representar el modelo de Markowitz y evaluar su rendimiento.

La cartera resultante asigna pesos de forma desigual entre los distintos activos disponibles, ponderando tanto su rendimiento ajustado al riesgo como su capacidad para contribuir a la diversificación del conjunto.




Figura 8. Pesos de los activos en el portafolio de mercado

Fuente: Elaboración propia

El activo con mayor peso en la cartera es MC.PA (LVMH) con un 25,56%, seguido muy de cerca por UNH (UnitedHealth) con un 25,38%. Estos activos comparten un perfil caracterizado por correlaciones relativamente bajas con otros componentes del portafolio. Las correlaciones entre activos se pueden obtener de los retornos de los activos en el conjunto de entrenamiento.

Por ejemplo, UNH presenta correlaciones de 0.43 con GOOGL o 0.48 con MSFT. Parece ser un buen amortiguador dentro del bloque estadounidense. LVMH, por su parte, exhibe una correlación moderada de 0.24 con Tencent (0700.HK) que demuestra su vinculación con el consumo de lujo global y su sensibilidad al ciclo asiático, lo cual añade valor desde el punto de vista de diversificación geográfica.

En tercer lugar, se sitúa 0700.HK (Tencent) con un peso del 14,33%. Esta acción china presenta correlaciones notablemente bajas con los principales valores tecnológicos de

Estados Unidos, como 0.09 con MSFT y 0.10 con AAPL, de ahí su utilidad como activo diversificador real dentro del portafolio. La baja dependencia estructural justifica su peso elevado.

Bitcoin (BTC-USD) también entra con un peso relevante del 8,26%. Sus correlaciones con acciones son generalmente bajas (entre 0.09 y 0.14), lo que lo convierte en una herramienta útil para diversificación, aunque el modelo regula su exposición para evitar que su alta volatilidad deteriore el rendimiento ajustado al riesgo.

El oro (GC=F) figura con un peso del 6,06%. Su correlación media con el resto de los activos es prácticamente nula. Pese a no aportar directamente retorno, sí desplaza la frontera eficiente hacia la izquierda y reduce la volatilidad global del portafolio.

Por su parte, GOOGL (6,65%) y MCD (6,11%) reciben una asignación moderada. En el caso de GOOGL, su buena relación rentabilidad-riesgo se ve penalizada por una fuerte correlación con otros valores del mismo sector como MSFT (0.69) y AAPL (0.57). Reduce así su aporte marginal a la diversificación. MCD, como conglomerado defensivo, presenta correlaciones más contenidas (0.38 con AAPL, 0.40 con JNJ) y aporta estabilidad.

También se asigna un peso apreciable a AMZN (5,46%), si bien algo limitado debido a su alta correlación con otros gigantes tecnológicos (0.62 con MSFT, 0.54 con AAPL).

De forma interesante, varios activos no reciben ningún peso en la solución óptima: AAPL, MSFT, BRK-B, JNJ, BABA, ASML, TSLA y SAN. En la mayoría de los casos, esto se debe a una combinación de redundancia y alta colinealidad con activos ya presentes.

Por ejemplo, MSFT y AAPL están fuertemente correlacionados entre sí (0.67) y con otros valores del bloque tecnológico. Incluirlos no añade beneficios de diversificación frente a GOOGL o AMZN.

ASML, pese a su origen europeo, tiene una correlación de 0.56 con MSFT y 0.52 con AAPL, por lo que se comporta más como un activo growth global que como una acción europea independiente.

SAN, aunque europeo, está muy correlacionado con el sector financiero estadounidense (0.59 con BRK-B).

TSLA tiene correlaciones relativamente contenidas con el bloque tecnológico, pero probablemente su perfil de riesgo no justifica su inclusión a favor de activos más estables.

La configuración del portafolio demuestra que la optimización de Markowitz pasa por una diversificación que no se obtiene simplemente añadiendo más acciones tecnológicas o grandes capitalizaciones, sino combinando activos con perfiles claramente diferenciados en términos de comportamiento y riesgo.

6.3. Evaluación de la cartera tangente

A continuación, se procede a evaluar los resultados de la cartera tangente del modelo de Markowitz fuera de muestra durante el periodo 2023-2024. A partir de la serie de rendimientos diarios se extraen tres métricas clave:

- **Rentabilidad anualizada (17,37%):** Se calcula la media aritmética diaria de la cartera y se multiplica por 252, el número aproximado de sesiones bursátiles del año.

$$\mu_{\text{ann}} = \bar{r} \times 252$$

- **Riesgo anualizado (14,39%):** Se parte de la desviación típica diaria de los rendimientos y se la convierte a frecuencia anual mediante la raíz cuadrada de 252.

$$\sigma_{\text{ann}} = \text{sd}(r_t) \times \sqrt{252}$$

- **Ratio de Sharpe (1,035):** El Sharpe compara la “recompensa” obtenida con el riesgo asumido. Concretamente, se resta a la rentabilidad anualizada la tasa libre de riesgo media del periodo (en este caso la misma media del rendimiento del bono estadounidense a 10 años en el periodo 2015-2024 que se ha empleado previamente para trazar la Línea del Mercado de Capitales) y se divide por la volatilidad anual.

$$S = \frac{\mu_{\text{ann}} - r_f}{\sigma_{\text{ann}}}$$

El rendimiento y el riesgo de esta cartera indican que, aunque se asume cierto nivel de volatilidad, dicho riesgo se mantiene en niveles aceptables y en línea con el perfil de una cartera diversificada que combina activos de distintos sectores, geografías y tipos de activos.

Como resultado del equilibrio entre rentabilidad y volatilidad, la cartera alcanza el ratio de Sharpe de 1,035, lo cual es considerablemente alto y demuestra una buena compensación del riesgo asumido. El resultado positivo, no obstante, era esperable debido al buen comportamiento de la renta variable en el periodo de prueba analizado.

Estos resultados servirán como benchmark o referencia comparativa para los modelos de optimización que se analizarán en las siguientes secciones del trabajo.

7. IMPLEMENTACIÓN DE MODELOS DE APRENDIZAJE PROFUNDO Y COMPARATIVA CON OPTIMIZACIÓN DE MARKOWITZ

En esta sección se introduce el enfoque práctico basado en aprendizaje profundo. El objetivo es evaluar si el uso de algoritmos de Deep Learning puede mejorar el desempeño del modelo clásico media-varianza de Markowitz en términos de rentabilidad ajustada al riesgo en condiciones reales de mercado.

7.1. Optimización con Deep Reinforcement Learning (DRL)

Como se ha introducido previamente en el apartado 5, la optimización de carteras mediante Deep Reinforcement Learning (DRL) permite que un agente aprenda dinámicamente a interactuar con el entorno del mercado y así ajusta los pesos de la cartera en función de la información disponible y la experiencia acumulada.

En este marco, el agente observa el estado del mercado, representado por indicadores técnicos y precios pasados, y toma decisiones sobre cómo distribuir el capital entre los distintos activos. Su objetivo es maximizar una función de recompensa, generalmente ligada al rendimiento acumulado de la cartera, ajustado al riesgo. El proceso de entrenamiento consiste en explorar distintas asignaciones de pesos, recibir retroalimentación (recompensa) y mejorar su política de inversión a lo largo del tiempo.

Para una comprensión más detallada de la implementación práctica del modelo DRL, se incluye en el Anexo II el código completo.

7.1.1. Datos y pasos previos

En este caso se utiliza Python, empleando bibliotecas especializadas en análisis financiero, procesamiento de datos y aprendizaje automático. Concretamente, se usan NumPy y Pandas para la manipulación eficiente de grandes volúmenes de datos financieros, yfinance para la descarga directa de datos históricos de mercado y Matplotlib para la visualización gráfica de los resultados. Además, PyTorch proporciona un entorno potente para desarrollar modelos complejos de redes neuronales y Gym facilita crear y gestionar el entorno interactivo necesario para el aprendizaje por refuerzo. Finalmente, se incorpora TA-Lib para añadir indicadores técnicos avanzados y scikit-learn (a través de train_test_split) para gestionar la división precisa del conjunto de datos en entrenamiento y validación.

La configuración inicial del entorno computacional asegura la reproducibilidad del experimento mediante el establecimiento de una semilla global (SEED = 42) seleccionada aleatoriamente. Así, se garantizan resultados comparables y consistentes entre diferentes ejecuciones del código.

El periodo analizado es coherente con el utilizado previamente en la optimización de Markowitz, abarcando desde el 1 de enero de 2015 hasta el 31 de diciembre de 2024. De manera idéntica, se dividen los datos históricos en un conjunto de entrenamiento (desde el 1 de enero de 2015 hasta el 31 de diciembre de 2021), un conjunto de prueba (desde el 1 de enero de 2023 hasta el 31 de diciembre de 2024) y un conjunto de validación en el año 2022 que, en este caso, como previamente en el modelo de Markowitz, tampoco será necesario utilizar pero se debe reservar con la necesidad de garantizar una base metodológica común y una comparación equitativa entre modelos. Al excluir el año 2022 del entrenamiento de Markowitz y DRL, se asegura que todos los modelos parten de la misma información histórica (2015-2021) y que la evaluación en el conjunto de prueba (2023-2024) se realice en condiciones estrictas de fuera de muestra, sin contaminación temporal ni fuga de información.

El universo de inversión es exactamente el mismo utilizado en el modelo media-varianza anterior, conformado por el conjunto diversificado de acciones y activos reales mencionados previamente (Google, Berkshire Hathaway, Microsoft, Apple, Johnson & Johnson, Alibaba, ASML, McDonald's, UnitedHealth, Tesla, Banco Santander, Amazon, LVMH, Bitcoin, Tencent y oro).

Los precios históricos diarios ajustados de cierre se obtienen directamente desde Yahoo Finance y se almacenan en un DataFrame de Pandas. Estos precios son posteriormente transformados en rendimientos discretos diarios. Se sigue así la coherencia metodológica con la sección anterior y se facilita la comparación directa de los resultados.

7.1.2. Definición del entorno personalizado de inversión

Para poder entrenar un agente de aprendizaje por refuerzo profundo (DRL) que aprenda a asignar dinámicamente los pesos de una cartera de inversión, se construye un entorno continuo personalizado basado en la librería Gym. Este entorno, denominado PortfolioEnv, simula un mercado financiero en el cual el agente toma decisiones de inversión diaria a lo largo del tiempo.

La función principal de este entorno es servir de interfaz entre el agente y el mercado, proporcionando observaciones del estado del entorno, permitiendo acciones (reparto de pesos entre activos) y generando recompensas en función del rendimiento obtenido.

El entorno PortfolioEnv presenta las siguientes características:

- Observaciones: El estado que percibe el agente consiste en una concatenación de indicadores técnicos normalizados para cada activo del universo de inversión. Concretamente, se calculan tres indicadores reales:
 - RSI (Relative Strength Index): mide la velocidad y el cambio de los movimientos de precio y se utiliza para identificar condiciones de sobrecompra o sobreventa.
 - MACD (Moving Average Convergence Divergence): refleja la relación entre dos medias móviles exponenciales y permite detectar cambios en la dirección, fuerza y duración de una tendencia.
 - ADX (Average Directional Index): cuantifica la fuerza de una tendencia, independientemente de su dirección.

Además, se añaden 11 valores de relleno (padding) por activo, con el fin de facilitar una posible expansión futura, dando lugar a un vector de dimensión $14 \times N$, donde N es el número de activos.

- Acciones: El agente elige un vector de pesos continuo (lo que le permite realizar asignaciones mucho más finas y precisas que en un entorno discreto):

$$\mathbf{a} = (a_1, a_2, \dots, a_N) \in \mathbb{R}^N$$

donde cada componente a_i es una puntuación real (positiva o negativa) que refleja la preferencia relativa del agente por asignar capital al activo i . Estas puntuaciones son generadas por la red neuronal como salida directa del modelo de política entrenado.

Sin embargo, este vector de puntuaciones no es directamente interpretable como pesos de inversión. Para transformarlo en una asignación válida de pesos de cartera, se aplica la función softmax, que garantiza que todos los pesos resultantes sean positivos y sumen uno:

$$w_i = \frac{e^{a_i}}{\sum_{j=1}^N e^{a_j}} \quad \text{para } i = 1, 2, \dots, N$$

dando lugar al vector de pesos:

$$\mathbf{w} = (w_1, w_2, \dots, w_N) \in \mathbb{R}^N \quad \text{con } w_i \geq 0 \text{ y } \sum_{i=1}^N w_i = 1$$

Este vector $\mathbf{w}$ representa la asignación diaria del capital entre los activos. El agente siempre mantiene una cartera completamente invertida, sin dejar capital sin asignar, y sin posiciones cortas, consistente con las restricciones impuestas en el modelo de Markowitz.

- **Recompensa:** Dado el vector de pesos asignado por el agente en el instante t , $\mathbf{w}_t = (w_{1,t}, w_{2,t}, \dots, w_{N,t})$, y el vector de retornos diarios observados al día siguiente $\mathbf{r}_{t+1} = (r_{1,t+1}, r_{2,t+1}, \dots, r_{N,t+1})$, el retorno diario de la cartera se calcula como:

$$r_{\text{cartera}, t+1} = \mathbf{w}_t^\top \mathbf{r}_{t+1} = \sum_{i=1}^N w_{i,t} \cdot r_{i,t+1}$$

La recompensa que recibe el agente se define como el logaritmo del retorno de la cartera:

$$R_{t+1} = \log(1 + r_{\text{cartera}, t+1})$$

Esta elección favorece decisiones que maximizan el crecimiento exponencial del capital y penaliza fuertemente pérdidas significativas.

Este entorno define, por tanto, un problema de decisión secuencial donde el agente debe aprender una política de asignación óptima de pesos para maximizar su rendimiento acumulado, en condiciones realistas y con restricciones similares a las de los modelos tradicionales.

7.1.3. Implementación del agente PPO

Para entrenar al agente de inversión dentro del entorno continuo definido previamente, se emplea el algoritmo Proximal Policy Optimization (PPO), muy utilizado por su estabilidad y eficiencia en tareas de aprendizaje por refuerzo profundo con espacios de acción continuos. Esta elección resulta particularmente adecuada en el contexto de asignación dinámica de pesos en carteras, donde el agente debe emitir decisiones continuas de inversión a lo largo del tiempo.

El agente se modela mediante una red neuronal definida por la clase Policy, que recibe como entrada el estado del entorno $\mathbf{s}_t \in \mathbb{R}^{n_s}$ (donde $n_s = 14 \times N$) y genera como salida una distribución normal multivariante sobre las acciones $\mathbf{a}_t \in \mathbb{R}^{n_a}$ (siendo $n_a = N$). La red se compone de los siguientes elementos:

- Capa base compartida: dos capas densas con 256 unidades y activación Tanh que extraen una representación útil del estado.
- Cabeza de política $\mu(s_t)$: produce la media del vector de acciones. La desviación estándar σ se aprende como un parámetro logarítmico independiente, común para todas las acciones. Las acciones se muestrean de la distribución gaussiana $\mathbf{a}_t \sim \mathcal{N}(\mu(s_t), \text{diag}(\sigma^2))$.
- Cabeza de valor $V(s_t)$: estima el valor esperado del estado actual, útil para el cálculo de las ventajas y el retorno objetivo.

Durante la simulación de cada episodio, el agente interactúa con el entorno y almacena una memoria de transiciones $(s_t, \mathbf{a}_t, c_t, V(s_t), \log \pi(\mathbf{a}_t | s_t))$, donde:

- c_t es la recompensa recibida en el paso t ,
- $\pi(\mathbf{a}_t | s_t)$ es la probabilidad de haber tomado la acción $\mathbf{a}_t$ según la política actual.

Una vez recolectadas las transiciones, se calcula la ventaja generalizada utilizando el método Generalized Advantage Estimation (GAE- λ). Dado un conjunto de recompensas $\{c_t\}_{t=0}^{T-1}$ y valores $\{V(s_t)\}_{t=0}^T$, la ventaja en cada instante se calcula como:

$$\delta_t = c_t + \gamma V(s_{t+1}) - V(s_t)$$

$$\hat{A}_t = \delta_t + \gamma \lambda \delta_{t+1} + \gamma^2 \lambda^2 \delta_{t+2} + \dots$$

donde:

- $\gamma \in (0,1)$ es el factor de descuento que pondera las recompensas futuras,
- $\lambda \in (0,1)$ regula el compromiso entre sesgo y varianza.

El retorno objetivo para entrenar la función de valor se define como:

$$\hat{R}_t = \hat{A}_t + V(s_t)$$

La ventaja se normaliza para mejorar la estabilidad numérica:

$$\hat{A}_t \leftarrow \frac{\hat{A}_t - \mu(\hat{A})}{\sigma(\hat{A}) + \varepsilon}$$

Con las ventajas y retornos computados, se actualizan los parámetros de la red usando el algoritmo PPO. Se define la razón de probabilidad entre la nueva política y la antigua como:

$$\psi_t(\theta) = \frac{\pi_\theta(\mathbf{a}_t | \mathbf{s}_t)}{\pi_{\theta_{\text{old}}}(\mathbf{a}_t | \mathbf{s}_t)}$$

que mide cuánto ha cambiado la probabilidad de seleccionar la acción $\mathbf{a}_t$ en el estado $\mathbf{s}_t$ al actualizar los parámetros.

A continuación, se aplica la pérdida clipped surrogate:

$$L_{\text{CLIP}}(\theta) = E_t[\min(\psi_t(\theta) \hat{A}_t, \text{clip}(\psi_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t)]$$

La función de pérdida total que se minimiza incluye tres componentes:

$$L(\theta) = -L_{\text{CLIP}}(\theta) + \frac{1}{2}(\hat{R}_t - V(\mathbf{s}_t))^2 - \beta \cdot \mathcal{H}[\pi_\theta(\cdot | \mathbf{s}_t)]$$

donde:

- $\mathcal{H}$ es la entropía de la política (mayor entropía promueve exploración),
- β es un coeficiente pequeño (en este caso 0.005),
- $\frac{1}{2}(\hat{R}_t - V(\mathbf{s}_t))^2$ es la pérdida de valor.

El proceso completo de entrenamiento se ejecuta a través de la función `train_policy()`, que simula múltiples episodios durante un número de épocas predefinido (por defecto, 30). En cada época se reinicia el entorno, el agente interactúa, recolecta datos y luego actualiza sus parámetros utilizando el procedimiento descrito. Al finalizar el entrenamiento, se obtiene una política entrenada capaz de asignar pesos óptimos a los activos en cada instante, maximizando el rendimiento ajustado al riesgo dentro del entorno financiero simulado.

7.1.4. Evaluación del agente PPO y construcción de la cartera

Una vez definido el entorno de inversión y entrenado el agente con el algoritmo PPO + GAE- λ , se procede a su evaluación sobre el conjunto de prueba, correspondiente al periodo 2023-2024. Este paso es fundamental para comprobar si el agente ha aprendido una política de inversión capaz de generalizar su comportamiento más allá de los datos de entrenamiento.

El agente se entrena utilizando el entorno `PortfolioEnv` construido a partir de los precios del conjunto de entrenamiento. Para evaluar la política aprendida con los datos comprendidos entre 2015 y 2021, se construye un nuevo entorno `PortfolioEnv` que contiene exclusivamente los precios del conjunto de prueba. A diferencia de la fase de entrenamiento, durante esta simulación el agente no realiza aprendizaje: simplemente

aplica la política ya entrenada, observando el estado del mercado cada día y generando la asignación óptima de pesos según su estrategia aprendida.

El bucle de simulación reproduce un recorrido completo del mercado durante 2023 y 2024. En cada paso el agente observa el estado actual del mercado, calcula la acción óptima, en este caso el valor medio de la distribución gaussiana generada por su política y ejecuta la asignación de pesos en el entorno, sin actualizar sus parámetros.

Al finalizar la simulación, se extraen los últimos pesos asignados por el agente a cada activo que reflejan la distribución final del capital al cierre del año 2024 y permiten interpretar cuál ha sido la estrategia final de inversión aprendida por el modelo.




Figura 9. Pesos de los activos en la cartera DRL

Fuente: Elaboración propia

Se observa que el modelo DRL asigna los pesos de forma más distribuida entre los activos en comparación con la cartera óptima de Markowitz. Ningún activo domina claramente el portafolio y todos los componentes reciben una asignación positiva, lo cual indica que el agente ha aprendido una estrategia diversificada y flexible.

Destacan Tencent (0700.HK) con el mayor peso (13,91%), seguida por oro (GC=F) y Apple (AAPL), ambos con asignaciones cercanas al 9%. También se observa un equilibrio interesante entre activos tecnológicos, defensivos y reales (como Bitcoin y oro). Esto parece indicar que el agente muestra capacidad para identificar perfiles de riesgo complementarios. En contraste con el modelo de Markowitz, que excluía por

completo a varios activos, el enfoque DRL aprovecha parcialmente todas las fuentes de diversificación disponibles.

7.1.5. Evaluación de la cartera construida con DRL

A continuación, se evalúa el comportamiento de la cartera en el conjunto de prueba (2023-2024) y se compara con el del modelo de Markowitz:

Modelo	Rentabilidad anual (%)	Volatilidad anual (%)	Ratio de Sharpe
Markowitz	17,37	14,39	1,035
DRL	18,16	11,31	1,386

Figura 10. Comparativa Markowitz vs DRL (23-24)

Fuente: Elaboración propia

Se observa que el modelo basado en aprendizaje por refuerzo profundo (DRL) supera al enfoque clásico de Markowitz en todos los aspectos clave de rendimiento. Con una rentabilidad anualizada ligeramente superior (18,16% frente a 17,37%), el modelo DRL destaca sobre todo por su menor nivel de riesgo (volatilidad del 11,31% frente al 14,39%), lo que se traduce en un ratio de Sharpe considerablemente más alto (1,386 vs 1,035). El agente ha logrado una asignación de cartera más eficiente, ofreciendo más rentabilidad por cada unidad de riesgo asumido. En conjunto, los resultados refuerzan la utilidad del DRL como herramienta para la optimización dinámica de carteras en entornos reales.

7.2. Optimización con predicciones LSTM

A continuación, se procede a implementar redes neuronales recurrentes. Concretamente se explorarán los modelos LSTM (Long Short-Term Memory), introducidos ya en el apartado 5. En este caso se usarán para predecir precios de activos financieros y construir carteras basadas en dichas predicciones. En comparación con el modelo de Markowitz, que parte de estimaciones históricas fijas de rentabilidad y riesgo, esta implementación trata de anticipar el comportamiento futuro del mercado y asignar los pesos en función del rendimiento esperado de cada activo.

El objetivo es evaluar si la anticipación del movimiento de los precios mejora la eficiencia del portafolio en comparación con los métodos tradicionales.

El uso de estos modelos no encuentra su principal valor en la precisión absoluta de las predicciones, principalmente si se trabaja a 2 años vista. No obstante, a pesar del alto nivel de ruido presente en los mercados financieros, la existencia de patrones recurrentes, inercia direccional y momentum relativo entre activos hace posible que estos modelos identifiquen relaciones secuenciales útiles para la toma de decisiones.

En este caso, se plantea el uso de un modelo Bidirectional LSTM (Bi-LSTM) para que trate de anticipar el comportamiento futuro, capturando no solo la dirección esperada, sino también la intensidad relativa de las variaciones de precio.

El objetivo no es predecir precios exactos, sino generar una señal de predicción suficiente para estimar retornos esperados relativos entre activos, a partir de los cuales se construyen los pesos de una cartera diversificada. Los activos con mayores retornos proyectados reciben mayor peso, aplicando una función de suavizado exponencial (softmax) sobre los retornos esperados para evitar sobreponderaciones extremas.

Se es plenamente consciente de la dificultad inherente a la predicción de precios en los mercados financieros. Cualquier modelo puede incluso predecir direcciones contrarias en el comportamiento de determinados activos. Sin embargo, el enfoque adoptado en este caso no pretende obtener predicciones infalibles, sino evaluar si, en conjunto, las señales generadas por el modelo aportan información útil para mejorar la asignación de activos. Al generar una predicción individual por activo y utilizarla como estimación de su rentabilidad futura, se busca comprobar si el sistema es capaz de capturar una ventaja estadística colectiva que justifique su aplicación dentro de un proceso de optimización de carteras.

Para consultar la implementación completa del modelo Bi-LSTM y los pasos de procesamiento asociados, se incluye el código detallado en el Anexo III.

7.2.1. Datos y pasos previos

Para implementar esta estrategia se vuelve a utilizar el lenguaje de programación Python, junto al conjunto de librerías especializadas en manipulación de datos, descarga de precios históricos y construcción de modelos de redes neuronales recurrentes. Concretamente, se emplean Pandas y NumPy para el procesamiento y análisis de datos estructurados, yfinance para la descarga directa de precios ajustados desde Yahoo Finance, scikit-learn (MinMaxScaler) para normalizar los datos antes del entrenamiento,

Keras y TensorFlow como frameworks principales para construir y entrenar las redes neuronales LSTM y Matplotlib para la visualización de resultados.

Además, se establece la semilla global de aleatoriedad (SEED = 42) en todas las librerías relevantes para garantizar la reproducibilidad de los resultados.

El universo de activos definido es el mismo utilizado en las secciones anteriores para los modelos de Markowitz y DRL, y la serie histórica de precios ajustados obtenida para cada activo es idéntica (desde el 1 de enero de 2015 hasta el 31 de diciembre de 2024) con la diferencia de que esta vez se debe utilizar el año 2022 como conjunto de validación. El conjunto de entrenamiento y el conjunto de prueba (o predicción, en este caso) son coherentes a los empleados anteriormente (2015-2021 y 2023-2024, respectivamente).

7.2.2. Configuración del método Bi-LSTM

El método adoptado para la predicción de precios se basa en entrenar un modelo independiente por activo, utilizando una arquitectura Bidirectional LSTM (Bi-LSTM). De esta forma, el modelo analiza cada serie temporal de precios en profundidad, capturando tanto patrones pasados como dependencias contextuales en ambas direcciones de la secuencia.

La función `lstm_training()` encapsula todo el proceso de configuración, preparación de datos y entrenamiento del modelo, y se ejecuta de forma iterativa para cada uno de los activos definidos en el universo de inversión. El procedimiento se estructura en las siguientes fases:

- Escalado de datos: Para asegurar la estabilidad del entrenamiento y mejorar la capacidad del modelo para detectar patrones relativos, los precios históricos de cada activo se escalan individualmente al rango $[0,1]$ mediante un `MinMaxScaler`. Este paso se usa en redes neuronales recurrentes para que los valores de entrada estén normalizados y faciliten el aprendizaje.

Dado un vector de precios $\mathbf{p} = (p_1, p_2, \dots, p_T)$, el valor escalado se calcula como:

$$\tilde{p}_t = \frac{p_t - \min(p)}{\max(p) - \min(p)} \quad \text{para } t = 1, 2, \dots, T$$

- Construcción de ventanas de entrenamiento: Una vez escalada la serie temporal, se generan pares de entrenamiento $(X_{\text{train}}, y_{\text{train}})$ aplicando una ventana móvil de longitud fija (lookback = 120 días) y un horizonte de predicción (horizon = 1).

Formalmente, para cada instante t tal que $t > \text{lookback}$, se construye una muestra de entrada como:

$$X^{(i)} = (\tilde{p}_{t-120}, \tilde{p}_{t-119}, \dots, \tilde{p}_{t-1}) \quad \text{y su etiqueta: } y^{(i)} = \tilde{p}_t$$

De este modo, el modelo aprende a predecir el valor de la serie en el instante t a partir de los valores observados en los 120 días anteriores. El conjunto de entrada final se organiza como un tensor tridimensional cuyas dimensiones son:

$$X_{\text{train}}: (n, 120, 1) \quad y_{\text{train}}: (n, 1)$$

donde n es el número de muestras generadas a partir de la serie temporal, 120 indica la longitud de la ventana temporal (lookback) y 1 representa que cada paso temporal contiene una única variable: el precio ajustado del activo.

- Arquitectura de la red: El modelo está compuesto por dos capas principales.
 - Una capa Bidirectional LSTM con 64 neuronas, que procesa la secuencia tanto en orden directo como inverso, generando una representación más rica del contexto temporal.
 - Una capa densa final que transforma la salida de la LSTM en la predicción del precio para el instante siguiente.

El objetivo del modelo es minimizar el error cuadrático medio (MSE) entre las predicciones y los valores reales:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n \left(y^{(i)} - \widehat{y}^{(i)} \right)^2$$

La red se entrena usando el optimizador Adam, frecuentemente utilizado por su rendimiento y adaptabilidad en tareas de aprendizaje profundo.

- Entrenamiento del modelo: El entrenamiento se realiza durante 50 épocas, con un tamaño de batch de 32 observaciones. Este proceso se lleva a cabo de forma independiente para cada activo, de modo que cada modelo se especializa en su propia serie temporal.

El resultado final es un diccionario de modelos, en el que cada activo tiene asociado su propia red entrenada y su objeto de escalado correspondiente.

La intención es obtener una mayor flexibilidad en el análisis posterior, ya que cada modelo puede evaluarse individualmente o integrarse como parte de una estrategia global de asignación de cartera.

7.2.3. Validación del método Bi-LSTM

Una vez entrenados los modelos Bi-LSTM para cada activo utilizando datos del periodo 2015-2021, se procede a evaluar su capacidad predictiva sobre el conjunto de validación, correspondiente al año 2022. En esta fase se pretende analizar hasta qué punto los modelos son capaces de generalizar su aprendizaje y anticipar correctamente el comportamiento de los precios en un entorno que no ha sido utilizado durante el entrenamiento.

Para cada activo, se extrae la serie de precios ajustados correspondiente a 2022. Estos datos se escalan con el mismo objeto MinMaxScaler utilizado durante el entrenamiento, preservando la coherencia de la transformación. Se generan las ventanas de entrada con longitud lookback = 120, y se predice el precio del día siguiente de cada ventana.

Formalmente, para cada instante t , el modelo recibe como entrada una secuencia de precios escalados:

$$\tilde{p}_{t-120}, \tilde{p}_{t-119}, \dots, \tilde{p}_{t-1}$$

y genera una predicción para el precio del día siguiente:

$$\hat{p}_t = f(\tilde{p}_{t-120}, \tilde{p}_{t-119}, \dots, \tilde{p}_{t-1})$$

donde f representa la función aprendida por el modelo Bi-LSTM y $\tilde{p}_t$ denota los precios escalados. El formato de entrada al modelo es un tensor tridimensional de forma $(n, 120, 1)$, donde n es el número de muestras generadas.

Las predicciones $\hat{p}_t$ se transforman de nuevo a su escala original aplicando la inversa del escalado:

$$\hat{P}_t = \text{Scaler}^{-1}(\hat{p}_t)$$

y se comparan con los precios reales observados P_t para evaluar el comportamiento del modelo en esta fase.

Es importante señalar que en esta fase de validación las predicciones se realizan con ventanas construidas exclusivamente con datos reales, es decir, cada predicción generada por el modelo se basa únicamente en precios históricos observados, sin ningún tipo de retroalimentación artificial.









El objetivo es comprobar si el modelo es capaz de captar correctamente las relaciones temporales presentes en los datos antes de pasar a tareas de mayor dificultad.

Posteriormente, en el conjunto de prueba (años 2023-2024), se adoptará un esquema autorregresivo y completamente a ciegas. En ese escenario más exigente, el modelo deberá apoyarse en sus propias predicciones previas para construir nuevas entradas y continuar generando estimaciones sucesivas sin ninguna información adicional real. A efectos prácticos, implica que los errores pueden propagarse y acumularse a lo largo del tiempo, lo que es un reto considerable en términos de estabilidad, realismo y precisión acumulada, especialmente al tratarse de una predicción de dos años completos.

Por lo tanto, los resultados obtenidos en la fase de validación no deben interpretarse como representativos del rendimiento fuera de muestra del modelo. Más bien, deben entenderse como una verificación intermedia que permite detectar posibles fallos o inconsistencias tempranas antes de aplicar el modelo a la predicción real.

Este paso sirve como un test de coherencia interna y de consistencia del aprendizaje, con el objetivo de confirmar si el modelo ha logrado capturar estructuras estadísticamente útiles en los datos históricos. Solo si el comportamiento del modelo en esta validación es razonable, tiene sentido confiar en su capacidad para extrapolar patrones futuros en ausencia total de información real.

Las gráficas generadas muestran, para cada activo, la evolución del precio real frente a la predicción del modelo durante el periodo de validación:






Figura 11. Predicciones de LSTM en el conjunto de validación

Fuente: Elaboración propia

Las líneas azules representan los precios reales, mientras que las líneas discontinuas naranjas corresponden a las predicciones generadas por el modelo Bi-LSTM para cada día, utilizando como entrada los 120 días anteriores reales (ventanas de entrenamiento deslizantes).

A pesar de la complejidad inherente a los mercados financieros y la elevada volatilidad de ciertos activos (como BTC-USD o TSLA), se observa que el modelo logra captar, en muchos casos, la dinámica de los movimientos de precio. Esto indica que el modelo ha aprendido ciertas estructuras secuenciales relevantes durante el entrenamiento.

Sin embargo, también se identifican casos donde el modelo suaviza en exceso los movimientos o presenta un pequeño desfase temporal, lo cual es esperable debido a la naturaleza conservadora de las redes LSTM y a la pérdida de precisión al aproximarse a patrones no lineales con alta variabilidad. En algunos activos más volátiles como BTC-USD, la predicción presenta mayor desviación respecto a la trayectoria real.

7.2.4. Predicción fuera de muestra (2023-2024)

Una vez validado el modelo sobre datos de 2022, se procede a generar las predicciones correspondientes al periodo de prueba o fuera de muestra, que abarca los años 2023 y 2024. Esta fase representa el verdadero reto del modelo, ya que se enfrenta a un escenario completamente desconocido, sin acceso a datos reales futuros.

Para cada activo del universo de inversión, se realiza una predicción diaria durante todo el horizonte de prueba. A diferencia de la validación, donde se utilizaban ventanas formadas exclusivamente por datos reales, en este caso se aplica un esquema autorregresivo, en el que las predicciones pasadas del modelo alimentan sucesivamente las siguientes entradas.

Primero se toma la serie histórica completa hasta el 31 de diciembre de 2022, que se representa como una secuencia escalada:

$$\tilde{p}_1, \tilde{p}_2, \dots, \tilde{p}_T$$

donde T corresponde al último día de 2022. A partir de los últimos 120 valores $(\tilde{p}_{T-119}, \dots, \tilde{p}_T)$, el modelo genera la primera predicción:

$$\hat{p}_{T+1} = f(\tilde{p}_{T-119}, \dots, \tilde{p}_T)$$

Esta predicción escalada se incorpora a la serie como entrada del siguiente paso, es decir:

$$\hat{p}_{T+2} = f(\tilde{p}_{T-118}, \dots, \hat{p}_{T+1})$$

y así sucesivamente. En términos generales, para cada día $t \in \{T + 1, T + 2, \dots, T + H\}$, donde H es el número de pasos del horizonte de prueba (alrededor de 500 días), se tiene:

$$\hat{p}_t = f(\hat{p}_{t-120}, \dots, \hat{p}_{t-1})$$

Este procedimiento simula un entorno real donde el modelo debe tomar decisiones sin conocer el futuro y depender únicamente de su historial predictivo.

A continuación, las predicciones se transforman de nuevo a su escala original (precios reales) mediante la inversa del escalado:

$$\hat{P}_t = \text{Scaler}^{-1}(\hat{p}_t)$$







y se comparan con los precios reales observados P_t . Una vez generadas todas las predicciones de precios, se calculan los retornos diarios estimados como variaciones relativas entre días consecutivos:

$$\hat{r}_t = \frac{\hat{P}_t - \hat{P}_{t-1}}{\hat{P}_{t-1}} \quad \text{para } t = T + 2, \dots, T + H$$

Estas series de retornos estimados por activo constituyen la base sobre la cual se derivarán los pesos de la cartera en el siguiente apartado. Se utilizará como fundamento las expectativas de rentabilidad generadas por el modelo.

Aunque el método autorregresivo introduce un riesgo acumulativo, ya que los errores de una predicción pueden propagarse y amplificarse en pasos posteriores, el objetivo principal no es lograr una precisión exacta día a día, sino comprobar si el modelo mantiene la direccionalidad general y la magnitud relativa de los movimientos en un horizonte amplio y realista.

A continuación, se compara visualmente la evolución de los precios reales con la trayectoria predicha por el modelo para cada activo:






Figura 12. Pronósticos de LSTM para los años 2023-2024

Fuente: Elaboración propia

A pesar de la complejidad del reto, los resultados obtenidos son alentadores en varios sentidos. En primer lugar, se observa que el modelo logra mantener la dirección general del movimiento en muchos activos, especialmente aquellos que siguen una tendencia clara durante el periodo.

Por ejemplo, en acciones como GOOGL, MSFT, AAPL, AMZN o BTC-USD, el Bi-LSTM proyecta trayectorias ascendentes que, aunque más suaves y moderadas que las reales, reproducen correctamente el sesgo alcista que dominó esos valores en el periodo considerado. Estas predicciones no anticipan los niveles exactos de precio, lo cual es esperable, pero sí capturan la dirección y el impulso relativo, que son precisamente las variables de mayor interés en la asignación de pesos dentro de una cartera.

En el caso de otros activos como ASML o BABA, las predicciones muestran una evolución no solo coherente con la tendencia general, sino también con ciertos patrones de desaceleración o estabilización a medio plazo.

No obstante, hay también activos en los que el modelo no consigue capturar correctamente la evolución real o incurre en desviaciones progresivas. En particular, en activos como BRK-B, MCD o SAN, se observa una cierta tendencia descendente artificial que no se refleja en los datos reales. Esta deriva bajista puede deberse a pequeñas desviaciones iniciales que se amplifican con el tiempo.

A pesar de estas limitaciones, el modelo logra en general distinguir aquellos activos con tendencia positiva y mayor fuerza de aquellos con comportamiento más débil o negativo. Cabe esperar que el conjunto de señales mejore el perfil riesgo-retorno de la cartera cuando se utilicen como base para la optimización.

7.2.5. Construcción de la cartera a partir de las predicciones LSTM

Una vez obtenidas las predicciones de precios para cada activo en el periodo 2023-2024, el siguiente paso consiste en transformarlas en señales de rentabilidad esperada y construir una cartera diversificada que se base en dichas estimaciones.

Las predicciones de precios se convierten en rendimientos diarios esperados mediante la fórmula de variación relativa entre días consecutivos. Con estas series, se construye una matriz de retornos con dimensiones (días $\times$ activos), sobre la cual se calculan los siguientes estadísticos fundamentales:

- Rentabilidad anual esperada por activo: media de los retornos diarios multiplicada por 252 sesiones.

$$\hat{\mu}_i = \bar{r}_i \cdot 252$$

- Volatilidad anual esperada por activo: desviación típica diaria multiplicada por la raíz cuadrada de 252.

$$\hat{\sigma}_i = \text{std } r_i \cdot 252$$

- Matriz de covarianza de retornos esperados: calculada a partir de los retornos predichos y escalada a frecuencia anual.

$$\hat{\Sigma} = \text{Cov}(R) \cdot 252$$

A pesar de calcular estas métricas, no se recurre a un proceso de optimización tradicional como en el modelo de Markowitz. En su lugar, se opta por un enfoque más directo, basado exclusivamente en los retornos proyectados por el modelo Bi-LSTM. Esta decisión se fundamenta en la propia naturaleza de las predicciones generadas por la red neuronal, que tienden a estar suavizadas y centradas en capturar las tendencias de fondo, más que en reflejar las fluctuaciones de corto plazo. Incorporar la varianza como criterio adicional podría introducir ruido o complejidad innecesaria en este contexto.

Adicionalmente, se prioriza la transparencia y la estabilidad computacional: el vínculo entre la predicción del modelo y la asignación de pesos es directo, interpretable y fácilmente replicable.

Concretamente, los pesos se derivan aplicando una transformación exponencial suavizada sobre los retornos estimados que puede interpretarse como una variante de la función softmax, en la que cada peso se define como:

$$w_i = \frac{e^{\alpha \cdot \hat{\mu}_i}}{\sum_j e^{\alpha \cdot \hat{\mu}_j}}$$

donde:

- $\hat{\mu}_i$ es el retorno anualizado estimado del activo i
- $\alpha = 1,3$ es un parámetro que controla el nivel de agresividad en la asignación: cuanto mayor es su valor, más se concentran los pesos en los activos con mejores perspectivas. En este caso, se ha elegido un valor intermedio que ofrece un equilibrio razonable entre concentración y diversificación.

Este cálculo, además de ser intuitivo y fácil de implementar, resulta especialmente atractivo porque la asignación de pesos se deriva directamente de los retornos esperados proyectados por el modelo, sin necesidad de resolver un problema de

optimización complejo. Los activos con mayores rendimientos estimados reciben un mayor peso, mientras que aquellos con perspectivas más débiles quedan automáticamente relegados a un segundo plano sin abandonar por completo la diversificación.




Figura 13. Pesos de los activos en la cartera LSTM

Fuente: Elaboración propia

Los activos con mayor peso en la cartera son Bitcoin (BTC-USD) con un 11,83% y Tesla (TSLA) con un 11,39%, ya que el modelo proyectó para ellos un rendimiento futuro relativamente elevado.

También destacan asignaciones importantes para compañías tecnológicas de gran capitalización como Microsoft (MSFT) con un 7,91%, Alphabet (GOOGL) con un 7,55%, Amazon (AMZN) con un 7,34% y Tencent (0700.HK) con un 7,83%. Esta preferencia por el sector tecnológico parece indicar que el modelo identificó señales alcistas consistentes dentro de este grupo, posiblemente por la tendencia prolongada que muchas de estas compañías mantuvieron en los datos históricos.

Por otro lado, se asignan pesos más moderados a compañías como BRK-B (3,22%), MCD (3,66%) o MC.PA (3,71%), ya que sus retornos estimados por el modelo fueron más contenidos.

La evaluación de la cartera construida se realizará en el siguiente apartado. De esta forma, se comparará directamente su rendimiento con los obtenidos en los métodos analizados anteriormente.

7.3. Comparativa final entre las distintas optimizaciones

Una vez implementadas las tres metodologías de optimización de carteras propuestas en este trabajo (el modelo clásico de Markowitz, el enfoque basado en aprendizaje por refuerzo profundo (DRL) y la estrategia guiada por predicciones generadas mediante modelos Bi-LSTM) se procede a realizar un análisis comparativo de sus rendimientos durante el periodo fuera de muestra 2023-2024.

Este periodo ha sido común a las tres estrategias y ha servido como banco de pruebas neutral para medir el comportamiento de las carteras construidas bajo supuestos, arquitecturas y lógicas radicalmente distintas.




Figura 14. Comparativa entre carteras (Markowitz vs LSTM vs DRL)

Fuente: Elaboración propia

La cartera tangente generada por el modelo media-varianza de Markowitz alcanzó una rentabilidad anualizada del 17,37%, con una volatilidad del 14,39% y por lo tanto un ratio de Sharpe de 1,035. El resultado es totalmente coherente con la naturaleza del modelo:

una estrategia razonablemente diversificada, con una rentabilidad aceptable, pero sin capacidad para anticipar dinámicas futuras ni adaptarse a cambios en el comportamiento del mercado.

Aunque eficaz como referencia, el modelo clásico presenta limitaciones evidentes: asume que las distribuciones de retornos pasadas son representativas del futuro, ignora factores no lineales y no incorpora ningún tipo de aprendizaje o ajuste.

En el caso del modelo de DRL, el rendimiento anualizado alcanzó el 18,16%, superando así ligeramente al modelo de Markowitz, pero lo más relevante fue la reducción sustancial del riesgo, con una volatilidad anual del 11,31%. De esta forma se alcanzó un ratio de Sharpe de 1,386, superior en un 34% al modelo tradicional.

Este resultado parece indicar que el agente PPO fue capaz de desarrollar una política de asignación eficiente, sensible al entorno y robusta frente a la variabilidad del mercado. La lógica adaptativa de este método lo convierte en una estrategia potencialmente muy interesante para perfiles inversores que priorizan la estabilidad y la consistencia.

Además, el DRL no requiere suposiciones explícitas sobre la distribución de retornos, ni estima directamente medias o varianzas: su conocimiento se basa exclusivamente en la experiencia adquirida durante el entrenamiento. Difícil de interpretar en términos clásicos, esta aproximación representa una alternativa flexible y potente a los métodos analíticos tradicionales.

Por último, la cartera construida en base a predicciones con modelos LSTM arroja una rentabilidad anualizada del 41,51%, con una volatilidad del 17,93% y un ratio de Sharpe de 2,176, muy por encima de los otros dos modelos. A pesar de que el riesgo es mayor en términos absolutos, la rentabilidad obtenida compensa ampliamente esa exposición. Se genera así una cartera con un rendimiento ajustado al riesgo claramente superior.

Aunque el modelo no acierta siempre la trayectoria exacta de los activos, el hecho de acertar la dirección general o la fuerza relativa en muchos de ellos basta para generar una asignación efectiva.

Los resultados refuerzan la hipótesis de que incluso una señal predictiva imperfecta puede ser útil para mejorar la asignación de activos, siempre que se utilice de forma coherente dentro de una estrategia sistemática y siendo consciente de que el paradigma del mercado puede cambiar de un año a otro y puede limitar mucho más la rigurosidad de las predicciones. Aun así, el modelo LSTM demuestra que existe información contenida en las secuencias históricas que puede explotarse a través de técnicas de

aprendizaje profundo, sin necesidad de asumir estructuras lineales o estacionariedad en los datos.

La comparativa muestra que, con ciertas limitaciones que se comentarán a continuación, los modelos de aprendizaje automático pueden aportar valor real en la optimización de carteras, no solo como herramientas de análisis, sino como motores de decisión.

8. CONCLUSIONES Y LIMITACIONES

Este trabajo ha explorado en profundidad el papel que desempeña la inteligencia artificial, y en particular el aprendizaje profundo, en la transformación de la gestión de carteras. A través de una comparación entre el modelo clásico de Markowitz, un agente de Deep Reinforcement Learning (DRL) entrenado con PPO y una estrategia basada en predicciones generadas por modelos Bi-LSTM, se ha demostrado que las técnicas de IA pueden aportar ventajas sustanciales en términos de rentabilidad ajustada al riesgo.

Los resultados empíricos muestran que, aunque el modelo de Markowitz sigue siendo una herramienta útil como referencia, los métodos basados en aprendizaje profundo son capaces de adaptarse mejor a las dinámicas del mercado y detectar patrones no lineales relevantes que los modelos clásicos no capturan.

No obstante, estos avances no están exentos de desafíos y limitaciones. En primer lugar, el entrenamiento de algoritmos de Deep Learning complejos exige una infraestructura computacional considerable. Aunque en este proyecto se ha logrado desarrollar modelos funcionales con medios limitados, la escalabilidad a entornos reales requeriría servidores avanzados, optimización de GPU y un pipeline robusto de gestión de datos.

En segundo lugar, los resultados de modelos como los basados en LSTM están condicionados por los datos históricos disponibles y por el supuesto implícito de que las relaciones pasadas entre activos pueden repetirse en el futuro. Sin embargo, los mercados financieros están en constante evolución y los cambios de régimen, eventos exógenos o innovaciones tecnológicas pueden invalidar las señales previamente aprendidas. En este sentido, cualquier sistema basado en predicción, por sofisticado que sea, corre el riesgo de quedar obsoleto o desalineado ante un cambio drástico en el entorno de mercado (Suárez-Cetrulo, Quintana, & Cervantes, 2023).

Además, para obtener conclusiones más sólidas y extrapolables, sería deseable realizar un backtest más complejo que incluya, por ejemplo, simulaciones con diferentes ventanas temporales, múltiples ciclos de mercado y validación cruzada temporal. Asimismo, podría haberse empleado técnicas como la simulación de Montecarlo para reflejar de forma más consistente la naturaleza aleatoria inherente a los modelos de Deep Learning y evaluar su comportamiento bajo múltiples iteraciones. Del mismo modo, en un entorno real, sería recomendable incorporar más fuentes de información, como variables macroeconómicas o datos alternativos a gran escala. Estas mejoras, sin

embargo, requieren recursos computacionales y tiempos de desarrollo que exceden el alcance de este trabajo.

Otro punto crítico es la ya comentada interpretabilidad de los modelos. Aunque se ha demostrado que las redes profundas y los agentes DRL pueden mejorar la asignación de activos, explicar por qué se toman ciertas decisiones sigue siendo un reto. La falta de transparencia puede dificultar su adopción en contextos regulados.

En conjunto, este trabajo demuestra que la inteligencia artificial, bien aplicada, puede enriquecer sustancialmente el proceso de optimización de carteras. No obstante, su adopción debe ir acompañada de una comprensión clara de sus limitaciones, una infraestructura adecuada y una reflexión continua sobre los riesgos emergentes que pueden surgir de su aplicación generalizada en los mercados financieros.

En el futuro, será fundamental avanzar en técnicas híbridas que combinen precisión predictiva con explicabilidad, así como en herramientas que permitan integrar estos modelos en la práctica sin perder el control humano. La fusión entre perfiles técnicos y financieros será clave para aprovechar todo el potencial de la IA en las finanzas.

ANEXOS

ANEXO I: CARTERA DE MARKOWITZ CON R

```
library(quantmod)
library(timeSeries)
library(fPortfolio)
library(caTools)
library(dplyr)
library(PerformanceAnalytics)
library(ggplot2)
library(zoo)
library(scales)

#####
##### PASOS PREVIOS #####
#####

# Vector de TICKERS

tickers <- c("GOOGL", "BRK-B", "MSFT", "AAPL", "JNJ", "GC=F", "BABA", "ASML",
            "MCD", "UNH", "TSLA", "SAN", "AMZN", "MC.PA", "BTC-USD", "0700.HK" )

# Extrayendo la data

ini_date      <- "2015-01-01"
test_start    <- "2023-01-01"           # inicio ventana test
test_end      <- "2024-12-31"           # fin ventana test
train_end     <- "2021-12-31"           # último día de estimación

PrecPort<- NULL
for (Ticker in tickers)
  PrecPort<-cbind(PrecPort, getSymbols(Ticker, from = ini_date, to = test_end,
                                     auto.assign=FALSE)[,4])

PrecPort

# Renombrando los encabezados de las columnas

colnames(PrecPort)<-tickers

# Calculando los retornos

RetPort <- na.omit(ROC(PrecPort, type="discrete"))
RetPort

train_ret <- RetPort[paste0("/", train_end)]
test_ret  <- RetPort[paste0(test_start, "/", test_end)]
# Copia xts para el evaluador
test_ret_eval <- test_ret              # objeto xts/zoo
```

```

# Convirtiendo los retornos en series de tiempo
RetPort <- as.timeSeries(RetPort)

RetPort

train_ret <- as.timeSeries(train_ret)
test_ret <- as.timeSeries(test_ret)

#####
##### FRONTERA Y PORTAFOLIOS EFICIENTES #####
#####

# Tasa libre de riesgo anual (bono 10Y)
getSymbols("GS10", src = "FRED", from = ini_date, to = test_end)
mean_risk_free_rate <- mean(GS10$GS10, na.rm = TRUE) / 100 # en decimal
cat("Tasa libre de riesgo media 2015-2024: ",
    round(100*mean_risk_free_rate, 2), "%\n\n")

spec <- portfolioSpec()
setRiskFreeRate(spec) <- mean_risk_free_rate/252

# Calculando la frontera eficiente

fronteraEff <- portfolioFrontier(train_ret, spec = spec, constraints = "LongOnly")

# Graficando la frontera
# En el gráfico, se pueden incorporar los siguientes elementos:
# 1: Frontera Eficiente
# 2: El portafolio con la mínima varianza global
# 3: Línea tangente al portafolio
# 4: Riesgo y retorno de cada activo
# 5: Portafolio con activos del mismo peso
# 6: Fronteras de dos activos
# 7: Portafolios de Monte Carlo
# 8: Ratio de Sharpe

plot(fronteraEff, c(1,2,3))

# Riesgos y Retornos de la frontera

Riesgo_Retorno <- frontierPoints(fronteraEff)

# Matrices de correlación y covarianza

MatrizCorr<-cor(train_ret)
MatrizCov<-cov(train_ret)

MatrizCov
MatrizCorr

# Pesos en las fronteras eficientes

```

```

fronteraPesos<-getWeights(fronteraEff)
colnames(fronteraPesos)<-tickers

# Puntos interesantes:

# Punto de la L?nea de Mercado de Capitales tangente a la Frontera Eficiente
LMC<-tangencyPortfolio(train_ret, spec=spec, constraints="LongOnly")
LMC

# Reporte de los pesos asignados:
LMC_Pesos<-getWeights(LMC)
DF_LMC_Pesos<-data.frame(LMC_Pesos)
acciones<-colnames(fronteraPesos)

# Paleta personalizada de 16 colores sobrios y elegantes
colores_elegantes <- c(
  "#3E5F8A", "#466B99", "#4E79A7", "#5685B5", "#5E91C3",
  "#669DD1", "#6EA9DF", "#77B5ED", "#7FC1FB", "#88CCFF",
  "#92D1F7", "#9CD6F0", "#A6DBE9", "#B0E0E2", "#BAD5D3",
  "#C4CAC4"
)

ggplot(data = DF_LMC_Pesos, aes(x = acciones, y = LMC_Pesos * 100, fill = acciones))+
  geom_bar(stat = "identity", colour = "black") +
  geom_text(
    aes(label = sprintf("%.2f %%", LMC_Pesos * 100)),
    vjust = -0.25, size = 2.5
  ) +
  scale_fill_manual(values = colores_elegantes, name = "Activos") +
  scale_y_continuous(labels = number_format(accuracy = 1)) +
  ggtitle("Pesos de los activos - Portafolio de mercado") +
  labs(x = "Activos", y = "Pesos") +
  theme_minimal(base_size = 12) +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 12),
    axis.title.x = element_text(face = "plain"),
    axis.title.y = element_text(face = "plain"),
    axis.text.x = element_text(angle = 45, hjust = 1, vjust = 1),
    axis.ticks.x = element_blank(),
    panel.grid.major.y = element_line(color = "gray80", size = 0.4),
    panel.grid.major.x = element_blank(),
    panel.grid.minor = element_blank(),
    legend.position = "none"
  )
)

# — 1. Función auxiliar para métricas anuales —————
eval_port <- function(weights, ret_test) {
  port_ret <- zoo(ret_test %*% weights, order.by = index(ret_test))
  ER_ann <- mean(port_ret) * 252 # retorno anual
  SD_ann <- sd (port_ret) * sqrt(252) # riesgo anual

```

```

Sharpe <- (ER_ann - mean_risk_free_rate) / SD_ann
c(Rendimiento = ER_ann, Riesgo = SD_ann, Sharpe = Sharpe)
}

# --- 2. Evaluar la cartera tangente (LMC) -----
LMC_Pesos <- getWeights(LMC)
perf_LMC <- eval_port(LMC_Pesos, test_ret_eval)

cat("==== Portafolio Tangente (fuera de muestra 2023-2024) ====\\n")
cat("Rendimiento anualizado: ", round(100*perf_LMC["Rendimiento"], 2), "%\\n")
cat("Riesgo anualizado:      ", round(100*perf_LMC["Riesgo"], 2), "%\\n")
cat("Sharpe ratio:          ", round(perf_LMC["Sharpe"], 3), "%\\n")

```

ANEXO II: CARTERA DRL CON PYTHON

```

# =====
# 0) LIBRERÍAS, PARÁMETROS Y **SEMILLA GLOBAL**
# =====

import datetime as dt, numpy as np, pandas as pd, yfinance as yf, random, torch, gym
import torch.nn as nn, torch.optim as optim, matplotlib.pyplot as plt, talib as ta
from sklearn.model_selection import train_test_split

SEED = 42 # ← reproducibilidad
random.seed(SEED)
np.random.seed(SEED)
torch.manual_seed(SEED)
torch.cuda.manual_seed_all(SEED)
torch.use_deterministic_algorithms(True)
torch.backends.cudnn.deterministic = True
torch.backends.cudnn.benchmark = False

START = dt.datetime(2015, 1, 1)
END = dt.datetime(2024, 12, 31)

TICKERS = [
    "GOOGL", "BRK-B", "MSFT", "AAPL", "JNJ", "GC=F", "BABA", "ASML",
    "MCD", "UNH", "TSLA", "SAN", "AMZN", "MC.PA", "BTC-USD", "0700.HK" ]
DEVICE = torch.device('cuda' if torch.cuda.is_available() else 'cpu')

# =====
# 1) DESCARGA Y PREPARACIÓN DE DATOS
# =====

px = yf.download(TICKERS, start=START, end=END, auto_adjust=False,
                 progress=False)['Close'].ffill().bfill()

# ---- NUEVO split -----
train_px = px.loc[:'2021-12-31'] # 2015-01-01 → 2021-12-31
val_px = px.loc['2022'] # año 2022
test_px = px.loc['2023':] # 2023 + 2024
# -----

ret_train = train_px.pct_change().dropna()
ret_val = val_px.pct_change().dropna()
ret_test = test_px.pct_change().dropna()

```

```

# =====
# 2) ENTORNO CONTINUO - EL AGENTE ELIGE PESOS CADA DÍA
# =====
class PortfolioEnv(gym.Env):
    """
    Observación: precios normalizados (log-ret), 14 indicadores * N
    Acción:      vector continuo de pesos (softmax → suman 1)
    Recompensa:  log-retorno diario de la cartera
    """
    def __init__(self, prices):
        super().__init__()
        self.px = prices.values
        self.ret = pd.DataFrame(prices).pct_change().fillna(0).values
        self.dates = prices.index
        self.n = self.px.shape[1]
        self.action_space = gym.spaces.Box(-1, 1, shape=(self.n,))
        obs_dim = self.n*14 # 14 indicadores por activo
        self.observation_space = gym.spaces.Box(-np.inf, np.inf, shape=(obs_dim,))
        self.action_space.seed(SEED) # ← semilla para acciones
        self._reset_internal()

    # ----- indicadores técnicos (3 reales + padding) -----
    def _tech(self, t):
        feat = []
        for c in range(self.n):
            win = self.px[max(0,t-100):t+1, c].astype(float)
            rsi = ta.RSI(win)[-1] if win.size>14 else 50
            macd = ta.MACD(win)[0][-1] if win.size>35 else 0
            adx = ta.ADX(win,win,win)[-1] if win.size>14 else 20
            feat += [rsi/100, macd/100, adx/100] + [0]*11
        return np.nan_to_num(feat, nan=0)

    def _state(self):
        return self._tech(self.t)

    # ----- API Gym -----
    def reset(self, *, seed: int | None = None, **kwargs):
        super().reset(seed=seed)
        self._reset_internal()
        return self._state()

    def _reset_internal(self):
        self.t = 0
        self.w = np.ones(self.n)/self.n # equiponderado
        self.port_val = 1.0

    def step(self, action):
        w_new = torch.softmax(torch.tensor(action), 0).cpu().numpy()
        r_next = (self.ret[self.t+1] @ w_new)
        self.port_val *= (1+r_next)
        reward = np.log(1+r_next)
        self.t += 1
        self.w = w_new
        done = (self.t >= len(self.ret)-2)
        return self._state(), reward, done, {}

```

```

# =====
# 3) AGENTE PPO + GAE-λ
# =====

class Policy(nn.Module):
    def __init__(self, s_dim, a_dim):
        super().__init__()
        self.net = nn.Sequential(nn.Linear(s_dim, 256), nn.Tanh(),
                                   nn.Linear(256, 256), nn.Tanh())

        self.mu = nn.Linear(256, a_dim)
        self.v = nn.Linear(256, 1)
        self.log_std = nn.Parameter(torch.zeros(a_dim))

    def forward(self, x):
        h = self.net(x)
        dist = torch.distributions.Normal(self.mu(h), self.log_std.exp())
        value = self.v(h)
        return dist, value

def compute_gae(rewards, values, gamma=0.97, lam=0.95):
    """Devuelve ventajas normalizadas + retornos con GAE"""
    values = values + [0] # v_{t+1} = 0 al final
    gae, advs, rets = 0, [], []
    for t in reversed(range(len(rewards))):
        delta = rewards[t] + gamma*values[t+1] - values[t]
        gae = delta + gamma*lam*gae
        advs.insert(0, gae)
        rets.insert(0, gae + values[t])
    advs = torch.tensor(advs, dtype=torch.float32, device=DEVICE)
    advs = (advs - advs.mean()) / (advs.std()+1e-8) # normaliza
    rets = torch.tensor(rets, dtype=torch.float32, device=DEVICE)
    return advs.unsqueeze(1), rets.unsqueeze(1)

def ppo_update(memory, policy, opt, eps=0.2):
    states, acts, rewards, vals, logp_old = map(list, zip(*memory))
    advs, rets = compute_gae(rewards, vals)
    states = torch.stack(states)
    acts = torch.stack(acts)
    logp_old = torch.stack(logp_old)

    for _ in range(4): # 4 epochs
        dist, val = policy(states)
        logp_new = dist.log_prob(acts).sum(-1, keepdim=True)
        ratio = (logp_new - logp_old).exp()
        surr1, surr2 = ratio*advs, torch.clamp(ratio, 1-eps, 1+eps)*advs
        entropy = dist.entropy().sum(-1, keepdim=True).mean()
        loss = -torch.min(surr1, surr2).mean() + 0.5*(rets-val).pow(2).mean() \
              - 0.005*entropy # ligera entropía
        opt.zero_grad(); loss.backward(); opt.step()

def train_policy(env, epochs=30):
    pol = Policy(env.observation_space.shape[0], env.action_space.shape[0]).to(DEVICE)
    opt = optim.Adam(pol.parameters(), 3e-4)
    for ep in range(epochs):

```

```

s = torch.tensor(env.reset(seed=SEED), dtype=torch.float32, device=DEVICE)
mem=[]; tot=0; done=False
while not done:
    dist, val = pol(s)
    a = dist.sample(); logp = dist.log_prob(a).sum()
    s2, r, done, _ = env.step(a.cpu().numpy())
    mem.append((s, a, torch.tensor([r], device=DEVICE), val, logp.detach()))
    s = torch.tensor(s2, dtype=torch.float32, device=DEVICE); tot += r
    ppo_update(mem, pol, opt)
    print(f"Epoch {ep+1:3d} | retorno episódico: {tot:.4f}")
return pol

# =====
# 4) ENTRENAMIENTO Y SIMULACIÓN 2023-2024
# =====
train_env = PortfolioEnv(train_px)
agent      = train_policy(train_env, epochs=30)

test_env = PortfolioEnv(test_px)
state, done = test_env.reset(seed=SEED), False
while not done:
    s = torch.tensor(state, dtype=torch.float32, device=DEVICE)
    with torch.no_grad():
        a = agent(s)[0].mean
    state, _, done, _ = test_env.step(a.detach().cpu().numpy())

weights_drl = pd.Series(test_env.w, index=test_px.columns)
weights_drl = weights_drl / weights_drl.sum()
print("\nPesos finales DRL:\n", weights_drl.round(4))

# =====
# MÉTRICAS
# =====
def metrics(w, ret):
    mu = (w * ret.mean()).sum() * 252
    sig = np.sqrt(w.values @ ret.cov().values @ w.values) * np.sqrt(252)
    rf = 0.0248
    return mu, sig, (mu - rf) / sig

# ——— resultados ———
mu_drl, sig_drl, sh_drl = metrics(weights_drl, ret_test) # DRL
mu_mk, sig_mk, sh_mk = 0.1737, 0.1439, (0.1737-0.0248)/0.1439 # Markowitz

# =====
# PALETA + ESTILO
# =====
COL = {"Markowitz": "#FF8C42", # naranja seco
       "DRL": "#4895EF"} # azul corporativo

plt.style.use("ggplot") # base coherente
plt.rcParams.update({
    "font.size": 11,
    "axes.facecolor": "white",
    "grid.color": "lightgray",
    "axes.edgecolor": "black",

```

```

    "axes.linewidth" : .8,
    "figure.dpi"      : 110
))

# -----
#  GRÁFICAS · Markowitz vs DRL
# -----

labels_md = ["Markowitz", "DRL"]
colors_md = [COL[l] for l in labels_md]

exp_ret_md = [mu_mk * 100, mu_drl * 100]
risk_md     = [sig_mk * 100, sig_drl * 100]
sharpe_md   = [sh_mk,      sh_drl]

fig, ax = plt.subplots(1, 3, figsize=(12, 4))

ax[0].bar(labels_md, exp_ret_md, color=colors_md, edgecolor="black")
ax[0].set_title("Rendimiento (%) Anualizado")
ax[0].set_ylabel("%")

ax[1].bar(labels_md, risk_md, color=colors_md, edgecolor="black")
ax[1].set_title("Desviación Estándar (%) Anualizada")
ax[1].set_ylabel("%")

ax[2].bar(labels_md, sharpe_md, color=colors_md, edgecolor="black")
ax[2].set_title("Ratio de Sharpe")
ax[2].set_ylabel("valor")

for a in ax:
    a.spines[['right', 'top']].set_visible(False)
    a.grid(axis="y", linestyle=":", alpha=.7)

plt.suptitle("Comparativa Markowitz vs DRL (2023-2024)",
             fontsize=13, fontweight="bold")
plt.tight_layout(rect=[0, 0, 1, 0.9])
plt.show()

# -----
#  TABLA · Markowitz · DRL
# -----

summary = pd.DataFrame({
    'R%': [mu_mk*100, mu_drl*100],
    'σ%': [sig_mk*100, sig_drl*100],
    'Sharpe': [sh_mk, sh_drl]
}, index=['Markowitz', 'DRL'])

print("\n===== COMPARACIÓN 2023-2024 =====\n")
print(summary.round(3))

```

ANEXO III: CARTERA LSTM CON PYTHON

```
# =====
# 0) LIBRERÍAS, PARÁMETROS Y **SEMILLA GLOBAL**
# =====

import pandas as pd
import numpy as np
import yfinance as yf
from sklearn.preprocessing import MinMaxScaler
from keras.models import Sequential
from keras.layers import LSTM, Dense, Bidirectional
import matplotlib.pyplot as plt
import tensorflow as tf, random, os
SEED=42; np.random.seed(SEED); tf.random.set_seed(SEED); random.seed(SEED);
os.environ["PYTHONHASHSEED"]=str(SEED)

assets = [
    "GOOGL", "BRK-B", "MSFT", "AAPL", "JNJ", "GC=F", "BABA", "ASML",
    "MCD", "UNH", "TSLA", "SAN", "AMZN", "MC.PA", "BTC-USD", "0700.HK" ]

# Fechas de interés
init_date      = '2015-01-01'
end_date_train = '2021-12-31'
end_date_val   = '2022-12-31'
end_date_pred  = '2024-12-31' # test / out-of-sample

# =====
# 1) DESCARGA Y PREPARACIÓN DE DATOS
# =====

df = yf.download(assets, start=init_date, end=end_date_pred, auto_adjust=False)

print(df.columns)

# Extraer solo el "Adj Close" de cada activo
df = df['Adj Close']
df = df.dropna()

# Verificar las primeras filas
print("Datos descargados desde Yahoo Finance: ")
print(df.head())

# Recortar el DataFrame a las fechas específicas
portfolio = df.loc[init_date:end_date_pred]

# =====
# 2) CONFIGURACIÓN DEL MODELO LSTM
# =====

def lstm_training(data,
                  lookback=120, horizon=1,
```

```

        neurons=64,
        epochs=50,
        batch_size=32):
    """
    Entrena un modelo **Bidirectional LSTM** por activo.
    """
    results = {}

    for asset in assets:
        print(f"Entrenando (Bi-LSTM): {asset}")

        # ----- 1. Escalado -----
        scaler = MinMaxScaler()
        train = data.loc[:end_date_train, asset].to_frame()
        train_scaled = scaler.fit_transform(train)

        # ----- 2. Ventanas -----
        X_train, y_train = [], []
        for i in range(lookback, len(train_scaled) - horizon):
            X_train.append(train_scaled[i-lookback:i, 0])
            y_train.append(train_scaled[i:i+horizon, 0])

        X_train = np.array(X_train).reshape((-1, lookback, 1))
        y_train = np.array(y_train)

        # ----- 3. Arquitectura -----
        model = Sequential([
            Bidirectional(
                LSTM(neurons, return_sequences=False),
                input_shape=(lookback, 1)
            ),
            Dense(horizon)
        ])
        model.compile(optimizer='adam', loss='mse')

        # ----- 4. Entrenamiento -----
        model.fit(X_train, y_train,
                  epochs=epochs,
                  batch_size=batch_size,
                  verbose=1)

        results[asset] = {"model": model, "scaler": scaler}

    return results

# =====
# 3) ENTRENAMIENTO Y VALIDACIÓN DEL MODELO LSTM
# =====

# Entrenamiento del modelo LSTM
lookback = 120
horizon = 1
models = lstm_training(portfolio, lookback, horizon)

```

```

print("Entrenamiento completado.")

# Validación del modelo LSTM
validation_results = {}
for asset, res in models.items():
    scaler, model = res["scaler"], res["model"]

    val = portfolio.loc[end_date_train:end_date_val, asset].values.reshape(-1, 1)
    val_scaled = scaler.transform(val)

    X_val = [val_scaled[i - lookback:i, 0]
              for i in range(lookback, len(val_scaled))]
    X_val = np.array(X_val).reshape((-1, lookback, 1))

    preds = scaler.inverse_transform(model.predict(X_val, verbose=0))

    validation_results[asset] = {
        "real": val[lookback:].flatten(),
        "predicted": preds.flatten()
    }

# Visualización de resultados de validación
plt.style.use("ggplot")
plt.rcParams.update({
    "font.size": 10, "axes.facecolor": "white", "grid.color": "lightgray",
    "axes.edgecolor": "black", "axes.linewidth": .8
})

for t, res in validation_results.items():
    plt.figure(figsize=(10, 5))
    plt.plot(res["real"], label="Real", color="#4895EF", lw=1.4)
    plt.plot(res["predicted"], label="Predicción", color="#FF8C42",
             ls="--", lw=1.6)
    plt.title(f"Validación LSTM · {t}", fontsize=12, fontweight="bold")
    plt.xlabel("Día"); plt.ylabel("Precio (USD)")
    plt.grid(axis="both", ls=":", alpha=.7); plt.legend(frameon=False)
    plt.tight_layout(); plt.show()

# =====
# 4) PREDICCIÓN USANDO EL MODELO LSTM
# =====

prediction_results = {}
steps_oos = len(portfolio.loc[end_date_val:end_date_pred])

for asset, res in models.items():
    scaler, model = res["scaler"], res["model"]

    hist = portfolio.loc[:end_date_val, asset].values.reshape(-1, 1)
    hist_scaled = scaler.transform(hist)

    series = hist_scaled.copy()
    preds_scaled = []

    for _ in range(steps_oos):

```

```

X_last = series[-lookback:].reshape(1, lookback, 1)
y_hat = model.predict(X_last, verbose=0) # shape (1, 1)
preds_scaled.append(y_hat[0, 0])
series = np.vstack([series, y_hat])

preds_real = scaler.inverse_transform(
    np.array(preds_scaled).reshape(-1, 1)
).flatten()
real_oos = portfolio.loc[end_date_val:end_date_pred, asset].values.flatten()

prediction_results[asset] = {"real": real_oos, "predicted": preds_real}

# Visualización de la predicción
plt.style.use("ggplot")
plt.rcParams.update({
    "font.size":10, "axes.facecolor":"white", "grid.color":"lightgray",
    "axes.edgecolor":"black", "axes.linewidth":.8
})

for t, res in prediction_results.items():
    plt.figure(figsize=(10, 5))
    plt.plot(res["real"], label="Real", color="#4895EF", lw=1.4)
    plt.plot(res["predicted"], label="Pronóstico", color="#FF8C42",
             ls="--", lw=1.6)
    plt.title(f"Pronóstico LSTM · {t}",
             fontsize=12, fontweight="bold")
    plt.xlabel("Día"); plt.ylabel("Precio (USD)")
    plt.grid(axis="both", ls=":", alpha=.7); plt.legend(frameon=False)
    plt.tight_layout(); plt.show()

# Predicciones calculadas por el modelo LSTM
lstm_predictions = {
    asset: (res["predicted"][1:] - res["predicted"][:-1]) / res["predicted"][:-1]
    for asset, res in prediction_results.items()
}

# =====
# 5) PESOS DERIVADOS DE LA LSTM
# =====

risk_free_rate = 0.0248 # Tasa libre de riesgo del 2.48%

# 1) Matriz de retornos predichos (filas = días, columnas = activos)
asset_list = list(lstm_predictions.keys())
ret_matrix = np.column_stack([lstm_predictions[a] for a in asset_list])

# 2) Estadísticos por activo
mu_hat = ret_matrix.mean(axis=0) * 252 # retorno anualizado
sigma_hat = ret_matrix.std(axis=0) * np.sqrt(252) #  $\sigma$  anualizada

```

```

cov_hat    = np.cov(ret_matrix, rowvar=False) * 252 # matriz  $\Sigma^{\wedge}$ 

# 3) Genera los pesos (elige un criterio)
alpha = 1.3 # agresividad
raw_w = np.exp(alpha * mu_hat) # Soft-max sobre retornos

weights = pd.Series(raw_w / raw_w.sum(), index=asset_list)
print("\nPesos LSTM:")
print(weights.round(4))

# 4) Métricas de la cartera LSTM
real_ret_df = (
    portfolio[asset_list] # precios reales
    .pct_change() # → retornos diarios
    .loc[end_date_val:end_date_pred] # periodo fuera de muestra
    .dropna()
)

# - ② estadísticos de la cartera construida con los PESOS ya fijados -
# vector de pesos en el mismo orden que las columnas de real_ret_df
w = weights.loc[real_ret_df.columns].values

mean_daily = real_ret_df.mean().values #  $\mu$  diarios
cov_daily = real_ret_df.cov().values #  $\Sigma$  diaria
mu_lstm_real = np.dot(w, mean_daily) * 252 # anualizado
var_lstm_real = np.dot(w, cov_daily @ w) * 252 # anualizado
std_lstm_real = np.sqrt(var_lstm_real)

# -----

# =====
# COMPARATIVA CON MARKOWITZ
# =====

# Datos de Markowitz
markowitz_expected_return = 0.1737
markowitz_std_dev = 0.1439

# Calcular ratios de Sharpe
markowitz_sharpe_ratio = (markowitz_expected_return - risk_free_rate) / markowitz_std_dev
lstm_sharpe_ratio = (mu_lstm_real - risk_free_rate) / std_lstm_real

# Resultados impresos
print("Resultados Markowitz:")
print(f"- Rendimiento anualizado: {markowitz_expected_return * 100:.2f}%")
print(f"- Desviación estándar anualizada: {markowitz_std_dev * 100:.2f}%")
print(f"- Ratio de Sharpe: {markowitz_sharpe_ratio:.4f}")

print("\nResultados LSTM:")
print(f"- Rendimiento anualizado: {mu_lstm_real * 100:.2f}%")
print(f"- Desviación estándar anualizada: {std_lstm_real * 100:.2f}%")
print(f"- Ratio de Sharpe: {lstm_sharpe_ratio:.4f}")

```

```

# -----
#  MÉTRICAS
# -----

drl_expected_return = 18.161 / 100
drl_std_dev         = 11.312 / 100
drl_sharpe_ratio    = 1.386


labels = ["Markowitz", "LSTM", "DRL"]

expected_returns = [
    markowitz_expected_return * 100,
    mu_lstm_real * 100,
    drl_expected_return * 100
]

std_devs = [
    markowitz_std_dev * 100,
    std_lstm_real * 100,
    drl_std_dev * 100
]

sharpe_ratios = [
    markowitz_sharpe_ratio,
    lstm_sharpe_ratio,
    drl_sharpe_ratio
]

# =====
#  PALETA · ESTILO
# =====

COL = {
    "Markowitz": "#FF8C42", # naranja seco
    "LSTM"      : "#2CA58D", # turquesa suave
    "DRL"       : "#4895EF"  # azul corporativo
}

plt.style.use("ggplot")
plt.rcParams.update({
    "font.size"      : 11,
    "axes.facecolor" : "white",
    "grid.color"     : "lightgray",
    "axes.edgecolor" : "black",
    "axes.linewidth" : .8,
    "figure.dpi"     : 110
})

# -----
#  GRÁFICAS · Markowitz · LSTM · DRL
# -----

bar_cols = [COL["Markowitz"], COL["LSTM"], COL["DRL"]]

# — Rendimiento anualizado —
plt.figure(figsize=(8, 6))

```

```

plt.bar(labels, expected_returns, color=bar_cols, edgecolor="black")
plt.title("Rendimiento (%) Anualizado")
plt.ylabel("%")
plt.ylim(0, max(expected_returns) * 1.15)
plt.grid(axis="y", linestyle=":", alpha=.7)
plt.show()

# — Desviación estándar anualizada —
plt.figure(figsize=(8, 6))
plt.bar(labels, std_devs, color=bar_cols, edgecolor="black")
plt.title("Desviación Estándar (%) Anualizada")
plt.ylabel("%")
plt.ylim(0, max(std_devs) * 1.15)
plt.grid(axis="y", linestyle=":", alpha=.7)
plt.show()

# — Ratio de Sharpe —
plt.figure(figsize=(8, 6))
plt.bar(labels, sharpe_ratios, color=bar_cols, edgecolor="black")
plt.title("Ratio de Sharpe")
plt.ylabel("Valor")
plt.ylim(0, max(sharpe_ratios) * 1.15)
plt.grid(axis="y", linestyle=":", alpha=.7)
plt.show()

```

BIBLIOGRAFÍA

- Adam, K., & Nagel, S. (2022). *Expectations Data in Asset Pricing*.
- Banco de España. (2022). *Inteligencia Artificial y Finanzas: Una Alianza Estratégica*.
- Bartram, S. M., Branke, J., & Motahari, M. (2020). *Artificial Intelligence in Asset Management*. CFA Institute Research Foundation.
- Benartzi, S., & Thaler, R. H. (2001). *Naive Diversification Strategies in Defined Contribution Saving Plans*.
- CFA Institute. (2022). *The Future Of Work In Investment Management*.
- Chandrasekaran, S. A., Sharma, M., & Sai, P. H. (2024). *Hybrid Transformer Model For Portfolio Allocation*.
- Financial Services Skills Commission. (2024). *Bridging the skills gap in a rapidly evolving sector*.
- Finio, M., & Downie, A. (3 de Julio de 2024). *Generative AI in banking*. Obtenido de IBM: <https://www.ibm.com/think/topics/generative-ai-banking>
- Fischer, T., & Krauss, C. (2018). *Deep learning with long short-term memory networks for financial market predictions*.
- Fujimoto, S., Hoof, H. v., & Meger, D. (2018). *Addressing Function Approximation Error in Actor-Critic Methods*.
- Funds Society. (11 de Julio de 2024). *The Assets of Robo-Advisors and Neo-Brokers Could Reach \$2.8 Trillion in 2024*. Obtenido de <https://www.fundsociety.com/en/news/business/the-assets-of-robo-advisors-and-neo-brokers-could-reach-2-8-trillion-in-2024/>
- Goodell, J. W., Kumar, S., Lim, W. M., & Pattnaik, D. (2021). *Artificial intelligence and machine learning in finance: Identifying foundations, themes, and research clusters from bibliometric analysis*. Journal of Behavioral and Experimental Finance.
- Gu, S., Kelly, B. T., & Xiu, D. (2019). *Empirical Asset Pricing via Machine Learning*.

- Hewamalage, H., Bergmeir, C., & Bandara, K. (2020). *Recurrent Neural Networks for Time Series Forecasting: Current Status and Future Directions*.
- Institutional Investor. (4 de Febrero de 2016). *CargoMetrics Cracks the Code on Shipping Data*. Obtenido de <https://www.institutionalinvestor.com/article/2bsxvqtd54melz40i3ri8/portfolio/cargo-metrics-cracks-the-code-on-shipping-data>
- Instituto de Finanzas Internacionales. (2020). *Machine learning governance*.
- IOSCO. (2025). *Artificial Intelligence in Capital Markets: Use Cases, Risks, and Challenges*.
- Jiang, Z., Xu, D., & Liang, J. (2017). *A Deep Reinforcement Learning Framework for the Financial Portfolio Management Problem*.
- Jung, C., Mueller, H., Pedemonte, S., Plances, S., & Thew, O. (2019). *Machine learning in UK financial services*. Bank of England & Financial Conduct Authority.
- Kahneman, D., & Tversky, A. (1979). *Prospect Theory: An Analysis of Decision under Risk*.
- Kenton, W. (26 de Junio de 2024). *Understanding Value at Risk (VaR) and How It's Computed*. Obtenido de Investopedia: <https://www.investopedia.com/terms/v/var.asp>
- Kumar, A., & Goetzmann, W. N. (2008). *Equity Portfolio Diversification*.
- Lillicrap, T. P., Hunt, J. J., Pritzel, A., Heess, N., Erez, T., Tassa, Y., . . . Wierstra, D. (2019). *Continuous control with deep reinforcement learning*.
- Luenberger, D. G. (1998). *Investment Science*. Oxford University Press.
- Ma, T., Wang, W., & Chen, Y. (2023). *Attention is all you need: An interpretable transformer-based asset allocation approach*.
- Mercer. (2024). *AI integration in investment management*.
- Michaud, R. O., & Michaud, R. O. (2008). *Efficient Asset Management: A Practical Guide to Stock Portfolio Optimization and Asset Allocation*. Oxford University Press.
- OpenAI. (2025). *Morgan Stanley utiliza evaluaciones de IA para modelar el futuro de los servicios financieros*. Obtenido de <https://openai.com/es-ES/index/morgan-stanley/>

- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). *Proximal Policy Optimization Algorithms*.
- Shirgaonkar, M. (17 de Julio de 2023). *Artificial Intelligence in Investment Management*.
Obtenido de CFA Society India: <https://cfasocietyindia.org/blog/artificial-intelligence-in-investment-management/>
- Šibalić, M. (19 de Febrero de 2025). *AI hedge fund with no humans beats the stock market*.
Obtenido de Finbold: <https://finbold.com/ai-hedge-fund-with-no-humans-beats-the-stock-market/>
- Simmonds, D., Waz, R., & Dannemiller, D. (29 de Mayo de 2024). *Retail investors may soon rely on generative AI tools for financial investment advice*. Obtenido de Deloitte: <https://www2.deloitte.com/us/en/insights/industry/financial-services/financial-services-industry-predictions/2024/ai-financial-advisor-for-retail-investment.html>
- Sokolov, A., Mostovoy, J., Ding, J., & Seco, L. A. (2021). *Building Machine Learning Systems for Automated ESG Scoring*.
- Suárez-Cetrulo, A. L., Quintana, D., & Cervantes, A. (2023). *Machine Learning for Financial Prediction Under Regime Change Using Technical Analysis: A Systematic Review*.
- Swedroe, L. (2023). *Artificial Intelligence, Textual Analysis and Hedge Fund Performance*.
Obtenido de alpha architect: <https://alphaarchitect.com/ai-funds/>
- Wikipedia. (28 de Diciembre de 2024). *Aladdin (BlackRock)*. Obtenido de [https://en.wikipedia.org/wiki/Aladdin_\(BlackRock\)](https://en.wikipedia.org/wiki/Aladdin_(BlackRock))
- Wilmott, P. (2007). *Paul Wilmott Introduces Quantitative Finance*. Wiley.
- Wu, S., Irsoy, O., Lu, S., Dabrovolski, V., Dredze, M., Gehrmann, S., . . . Mann, G. (2023). *BloombergGPT: A Large Language Model for Finance*.
- Wüthrich, M. V., & Merz, M. (2022). *Statistical Foundations of Actuarial Learning and its Applications*. Springer.
- Yang, A., Ye, Q., & Zhai, J. (2024). *Volatility forecasting with Hybrid-long short-term memory models: Evidence from the COVID-19 period*.
- Zhang, C., Liang, S., Lyu, F., & Fang, L. (2020). *Stock-Index Tracking Optimization Using Auto-Encoders*.

Zhang, Z., Zohren, S., & Roberts, S. (2021). *Deep Learning for Portfolio Optimization*.

Zhao, Z., & Welsch, R. E. (2024). *Hierarchical Reinforced Trader (HRT): A Bi-Level Approach for Optimizing Stock Selection and Execution*.